

**BỘ GIÁO DỤC VÀ ĐÀO TẠO BỘ NÔNG NGHIỆP VÀ MÔI TRƯỜNG
TRƯỜNG ĐẠI HỌC THỦY LỢI**



ĐINH QUỐC VIỆT

**NGHIÊN CỨU VÀ ỨNG DỤNG HỆ THỐNG PHÁT HIỆN
CUỘC GỌI LỬA ĐẢO SỬ DỤNG HỌC MÁY**

ĐỒ ÁN TỐT NGHIỆP

HÀ NỘI, NĂM 2026

BỘ GIÁO DỤC VÀ ĐÀO TẠO BỘ NÔNG NGHIỆP VÀ MÔI TRƯỜNG
TRƯỜNG ĐẠI HỌC THỦY LỢI

ĐINH QUỐC VIỆT

**NGHIÊN CỨU VÀ ỨNG DỤNG HỆ THỐNG PHÁT HIỆN
CUỘC GỌI LỪA ĐẢO SỬ DỤNG HỌC MÁY**

Ngành: Trí tuệ nhân tạo và khoa học dữ liệu

Mã số: 7480205

NGƯỜI HƯỚNG DẪN TS. Tạ Quang Chiểu

HÀ NỘI, NĂM 2026

ĐÌNH QUỐC VIỆT

ĐỒ ÁN

HÀ NỘI, NĂM 2026



CỘNG HÒA XÃ HỘI CHỦ NGHĨA VIỆT NAM

Độc lập – Tự do – Hạnh phúc



NHIỆM VỤ ĐỒ ÁN TỐT NGHIỆP

Họ tên sinh viên: Đinh Quốc Việt

Hệ đào tạo: Đại học chính quy

Lớp: 64TTNT.NB

Ngành: Trí tuệ nhân tạo và khoa học dữ liệu

Khoa: Công nghệ thông tin

1. TÊN ĐỀ TÀI

NGHIÊN CỨU VÀ ỨNG DỤNG HỆ THỐNG PHÁT HIỆN CUỘC GỌI LỪA ĐẢO SỬ DỤNG HỌC MÁY

2. CÁC TÀI LIỆU CƠ BẢN

- [1] X. Wang, J. Yamagishi, M. Todisco, H. Delgado and N. Evans, "ASVspoof 2021: Towards Spoofed and Deepfake Speech Detection in the Wild," in Proc. Interspeech, Brno, Czech Republic, 2021.
- [2] J. Kim, M. Todisco, H. Delgado and N. Evans, "Audio Anti-Spoofing using Integrated Spectro-Temporal Graph Attention Networks," in Proceedings of ICASSP 2022, Singapore, 2022.
- [3] A. Gulati, J. Qin, C. Chiu, N. Parmar, Y. Zhang, J. Yu, W. Han, S. Wang, Z. Zhang and Y. Wu, "Conformer: Convolution-augmented Transformer for Speech Recognition," in Proceedings of INTERSPEECH 2020.
- [4] A. Joulin, E. Grave, P. Bojanowski and T. Mikolov, "Bag of Tricks for Efficient Text Classification," in Proceedings of EACL 2017, Valencia, Spain, 2017.

[5] Một số tài liệu liên quan khác

3. NỘI DUNG CÁC PHẦN THUYẾT MINH VÀ TÍNH TOÁN

Nội dung các phần	Tỷ lệ
Chương 1: Giới thiệu tổng quan	15%
Chương 2: Cơ sở lý thuyết	30%
Chương 3: Xây dựng mô hình và ứng dụng	50%
Kết luận và hướng phát triển	5%

4. GIÁO VIÊN HƯỚNG DẪN TỪNG PHẦN

Giáo viên hướng dẫn toàn bộ quá trình thực hiện đồ án: **TS. Tạ Quang Chiêu**

5. NGÀY GIAO NHIỆM VỤ ĐỒ ÁN TỐT NGHIỆP

Ngày..... tháng.....năm 2026

Trưởng Bộ môn
(Ký và ghi rõ họ tên)

Giáo viên hướng dẫn chính
(Ký và ghi rõ họ tên)

Nhiệm vụ Đồ án tốt nghiệp đã được Hội đồng chấm thi tốt nghiệp của Khoa thông qua

Ngày..... tháng.....năm 2026

Chủ tịch Hội đồng
(Ký và ghi rõ họ tên)

Sinh viên đã hoàn thành và nộp bản Đồ án tốt nghiệp cho Hội đồng thi

Ngày..... tháng.....năm 2026

Sinh viên làm Đồ án tốt nghiệp
(Ký và ghi rõ họ tên)



TRƯỜNG ĐẠI HỌC THỦY LỢI
KHOA CÔNG NGHỆ THÔNG TIN

BẢN TÓM TẮT ĐỀ CƯƠNG ĐỒ ÁN TỐT NGHIỆP

Tên đề tài: Nghiên cứu và ứng dụng hệ thống phát hiện cuộc gọi lừa đảo sử dụng học máy

Sinh viên thực hiện: Đinh Quốc Việt

Lớp: 64TTNT.NB

Mã sinh viên: 2251262659

Số điện thoại: 0943178267

Email: 2251262659@e.tlu.edu.vn

Giáo viên hướng dẫn: TS. Tạ Quang Chiểu

TÓM TẮT ĐỀ TÀI

Đề tài tập trung nghiên cứu và xây dựng một hệ thống phát hiện cuộc gọi lừa đảo dựa trên việc kết hợp phân tích đặc trưng giọng nói và nội dung hội thoại. Trong bối cảnh các công nghệ tổng hợp giọng nói bằng trí tuệ nhân tạo ngày càng phát triển, các hình thức giả mạo giọng nói được sử dụng rộng rãi trong các hoạt động lừa đảo, gây ra nhiều rủi ro cho người dùng. Do đó, việc xây dựng một hệ thống có khả năng tự động nhận diện và cảnh báo sớm các cuộc gọi có dấu hiệu giả mạo mang ý nghĩa thực tiễn cao.

Hệ thống đề xuất tiếp nhận dữ liệu âm thanh từ các cuộc gọi đầu vào, thực hiện trích xuất và phân tích đặc trưng giọng nói nhằm phát hiện các dấu hiệu bất thường hoặc giả mạo do AI tạo ra. Đồng thời, tín hiệu âm thanh được chuyển đổi thành văn bản thông qua các kỹ thuật nhận dạng giọng nói, từ đó áp dụng các phương pháp xử lý ngôn ngữ

tự nhiên kết hợp mô hình học máy/học sâu để phân tích nội dung hội thoại và phát hiện các dấu hiệu liên quan đến hành vi lừa đảo.

Các thông tin thu được từ hai nguồn dữ liệu sẽ được kết hợp để đưa ra đánh giá tổng thể về cuộc gọi. Hệ thống sử dụng các mô hình học máy/học sâu để phân loại mức độ rủi ro của cuộc gọi, qua đó nâng cao độ chính xác và độ tin cậy so với việc chỉ sử dụng một nguồn thông tin riêng lẻ.

CÁC MỤC TIÊU CHÍNH

Mục tiêu tổng quát: Xây dựng hệ thống phát hiện cuộc gọi lừa đảo dựa trên phân tích giọng nói và nội dung hội thoại nhằm cảnh báo sớm và giảm thiểu rủi ro.

Mục tiêu cụ thể

Mục tiêu 1: Nghiên cứu và tổng quan các phương pháp trong và ngoài nước liên quan đến phát hiện cuộc gọi lừa đảo, nhận dạng giọng nói giả và các phương pháp phân tích nội dung hội thoại bằng xử lý ngôn ngữ tự nhiên.

Mục tiêu 2: Thu thập và xây dựng bộ dữ liệu gồm: Dữ liệu âm thanh (giọng nói thật và giọng nói giả) Nội dung hội thoại có và không có dấu hiệu lừa đảo phục vụ cho việc huấn luyện và đánh giá mô hình.

Mục tiêu 3: Xây dựng mô hình phát hiện giọng nói giả nhằm phân biệt giữa giọng nói thật và giọng nói được tạo bởi AI.

Mục tiêu 4: Phát triển mô hình phân tích nội dung hội thoại để phát hiện các dấu hiệu lừa đảo trong văn bản.

Mục tiêu 5: Thiết kế phương pháp kết hợp thông tin từ giọng nói và nội dung hội thoại nhằm nâng cao độ chính xác và độ tin cậy của hệ thống.

Mục tiêu 6: Xây dựng ứng dụng phát hiện cuộc gọi lừa đảo có khả năng tự động phân tích và hiển thị kết quả đánh giá mức độ nguy cơ của cuộc gọi.

Mục tiêu 7: Đánh giá hiệu năng của hệ thống trên tập dữ liệu thử nghiệm để kiểm chứng hiệu quả và mức độ phù hợp của mô hình trong bài toán phát hiện cuộc gọi lừa đảo.

KẾT QUẢ DỰ KIẾN

- Xây dựng được mô hình phát hiện giọng nói giả với độ chính xác đạt mức chấp nhận được trên tập dữ liệu thử nghiệm.
- Xây dựng được mô hình phân tích nội dung hội thoại có khả năng nhận diện các dấu hiệu lừa đảo trong văn bản.
- Thiết kế được phương pháp kết hợp thông tin từ giọng nói và nội dung hội thoại, giúp nâng cao hiệu quả phát hiện so với từng phương pháp riêng lẻ.
- Phát triển giao diện trực quan, giúp người dùng dễ dàng sử dụng và theo dõi kết quả phân tích.
- Đánh giá và so sánh hiệu năng của các phương pháp thông qua các chỉ số như độ chính xác, precision, recall...

TIẾN ĐỘ THỰC HIỆN

TT	Thời gian	Nội dung công việc	Kết quả dự kiến đạt được
1	23/03/2026 – 06/04/2026	Nghiên cứu tổng quan: Tìm hiểu các phương pháp phát hiện cuộc gọi lừa đảo, nhận dạng giọng nói giả và phân tích nội dung	Nắm vững cơ sở lý thuyết và lựa chọn hướng tiếp cận phù hợp
2	07/04/2026 – 27/04/2026	Thu thập và tiền xử lý dữ liệu: Thu thập audio và hội thoại,	Xây dựng bộ dữ liệu hoàn chỉnh phục vụ huấn luyện

			làm sạch, chuẩn hóa dữ liệu	
3	28/04/2026 12/05/2026	–	Xây dựng mô hình phát hiện giọng nói giả	Có mô hình phân biệt giọng thật/giả và kết quả đánh giá ban đầu
4	13/05/2026 27/05/2026	–	Xây dựng hệ thống chuyển giọng nói thành văn bản và mô hình phân tích nội dung	Hoàn thiện chuyển đổi audio sang text và mô hình phân loại nội dung
5	28/05/2026 08/06/2026	–	Tích hợp và tối ưu hệ thống: Kết hợp kết quả từ giọng nói và nội dung	Hệ thống hoàn chỉnh, cải thiện độ chính xác
6	09/06/2026 18/06/2026	–	Xây dựng ứng dụng demo	Hoàn thiện ứng dụng có thể chạy thử
7	19/06/2026 28/06/2026	–	Viết báo cáo và chuẩn bị bảo vệ	Hoàn thành báo cáo đề án tốt nghiệp và slide thuyết trình

LỜI CAM ĐOAN

Em xin cam đoan toàn bộ nội dung trong đồ án “Nghiên cứu và ứng dụng hệ thống phát hiện cuộc gọi lừa đảo sử dụng học máy” là kết quả nghiên cứu do chính cá nhân em thực hiện dưới sự hướng dẫn của giảng viên hướng dẫn. Các kết quả nghiên cứu, số liệu và nội dung trong đồ án được thực hiện và trình bày một cách trung thực, khách quan, đồng thời chưa từng xuất hiện trong bất kỳ công trình khoa học nào khác. Toàn bộ tài liệu và nguồn tham khảo sử dụng trong đồ án đều được trích dẫn và trình bày rõ ràng trong danh mục tài liệu tham khảo theo quy định. Trong đồ án này, em cam kết không sao chép nội dung từ bất kỳ nghiên cứu hay tài liệu của cá nhân, tổ chức khác mà không có trích dẫn hợp lệ. Em xin hoàn toàn chịu trách nhiệm nếu có bất kỳ sai sót hoặc thiếu trung thực nào trong nội dung!

Tác giả ĐATN

Đinh Quốc Việt

LỜI CẢM ƠN

Kính thưa thầy cô, trong suốt quá trình học tập tại Trường Đại học Thủy Lợi, em đã nhận được nhiều sự quan tâm, giúp đỡ và tạo điều kiện thuận lợi từ nhà trường, quý thầy cô, bạn bè và gia đình. Những kiến thức từ cơ bản đến chuyên ngành mà em được trang bị rất quý báu, giúp em có nền tảng vững chắc cho công việc và định hướng tương lai sau này.

Trong suốt quá trình thực hiện đề tài “Nghiên cứu và ứng dụng hệ thống phát hiện cuộc gọi lừa đảo sử dụng học máy”, từ khi hình thành ý tưởng đến khi hoàn thiện nội dung, em luôn nhận được sự hướng dẫn tận tình của thầy TS. Tạ Quang Chiêu. Nhờ sự hướng dẫn và góp ý của thầy, em đã có định hướng rõ ràng hơn, vượt qua những khó khăn và hoàn thành đồ án tốt nhất. Em rất biết ơn thầy vì sự hỗ trợ và hướng dẫn trong quá trình thực hiện đồ án.

Em cũng xin chân thành cảm ơn gia đình và bạn bè đã luôn ở bên, động viên và hỗ trợ em trong thời gian học tập và hoàn thành đồ án. Mặc dù đã cố gắng hết sức để hoàn thiện đề tài, do hạn chế về thời gian và kinh nghiệm, đồ án không thể tránh khỏi những thiếu sót. Em rất mong nhận được sự thông cảm và những ý kiến đóng góp quý báu từ thầy cô để đề tài được hoàn thiện hơn.

Cuối cùng, em xin kính chúc thầy cô sức khỏe dồi dào, hạnh phúc và thành công trong sự nghiệp giảng dạy. Em xin chân thành cảm ơn!

MỤC LỤC

DANH MỤC CÁC HÌNH ẢNH	v
DANH MỤC BẢNG BIỂU	vi
DANH MỤC CÁC TỪ VIẾT TẮT VÀ GIẢI THÍCH CÁC THUẬT NGỮ	vii
CHƯƠNG 1 GIỚI THIỆU TỔNG QUAN	1
1.1 Lý do chọn đề tài	1
1.2 Mục tiêu đồ án	3
1.2.1 Mục tiêu tổng quát	3
1.2.2 Mục tiêu cụ thể	3
1.3 Đối tượng, phạm vi nghiên cứu	4
1.3.1 Đối tượng nghiên cứu	4
1.3.2 Phạm vi nghiên cứu	4
CHƯƠNG 2 CƠ SỞ LÝ THUYẾT	5
2.1 Tổng quan về học máy	5
2.2 Tổng quan về học sâu	6
2.3 Xử lý tín âm thanh	7
2.4 Xử lý ngôn ngữ tự nhiên	8
2.5 Các mô hình sử dụng cho bài toán	9
2.5.1 Mô hình Conformer	9
2.5.2 Mô hình AASIST	13
2.5.3 Mô hình FastText	15
2.6 Các hệ số đánh giá mô hình	16
2.6.1 Chỉ số AUC	16
2.6.2 Chỉ số EER	18
2.6.3 Chỉ số F1-score, Precision, Recall	19
CHƯƠNG 3 XÂY DỰNG MÔ HÌNH VÀ ỨNG DỤNG	21
3.1 Phân tích bài toán	21
3.1.1 Mô tả chi tiết bài toán	21
3.1.2 Quy trình thực hiện	22
3.2 Các công cụ thư viện sử dụng	23
3.2.1 Môi trường thực nghiệm	23

3.2.2 Các thư viện chính được sử dụng	23
3.3 Dữ liệu và tiền xử lý	24
3.3.1 Thu thập dữ liệu	24
3.3.2 Phân tích dữ liệu	26
3.3.3 Tiền xử lý dữ liệu	30
3.4 Triển khai mô hình và ứng dụng	35
3.4.1 Huấn luyện, đánh giá mô hình Conformer	35
3.4.2 Huấn luyện, đánh giá mô hình AASIST	38
3.4.3 Huấn luyện đánh giá mô hình FastText	40
3.4.4 Đánh giá tổng quan quá trình huấn luyện mô hình	43
3.5 Thử nghiệm các mô hình khác	43
3.6 Xây dựng ứng dụng	45
KẾT LUẬN	51
TÀI LIỆU THAM KHẢO	52

DANH MỤC CÁC HÌNH ẢNH

Hình 2.1 Sơ đồ phân cấp Trí tuệ nhân tạo, Học máy, Học sâu	5
Hình 2.2 Quy trình tổng quát xử lý tín hiệu âm thanh	7
Hình 2.3 Cấu trúc tổng quan Conformer	9
Hình 2.4 Cấu trúc Conformer Blocks	11
Hình 2.5 Cấu trúc tổng quan AASIST	13
Hình 2.6 Sự khác biệt giữa Word2Vec và FastText	15
Hình 2.7 Đường cong ROC và diện tích AUC	17
Hình 2.8 Biểu đồ minh họa Equal Error Rate	18
Hình 3.1 Quy trình thực hiện	22
Hình 3.2 Quy trình tạo bộ dữ liệu văn bản hội thoại	26
Hình 3.3 Biểu đồ Waveform trực quan	27
Hình 3.4 Biểu đồ Mel Spectrogram trực quan	27
Hình 3.5 Minh họa dữ liệu văn bản hội thoại	28
Hình 3.6 Số lượng mỗi lớp scam và normal của dữ liệu văn bản hội thoại	29
Hình 3.7 Biểu đồ phân bố độ dài từng văn bản trong dữ liệu	29
Hình 3.8 Mel Spectrogram trước và sau khi chuẩn hóa 16khz	31
Hình 3.9 Cắt đoạn tín hiệu âm thanh	32
Hình 3.10 Lọc đoạn âm thanh có năng lượng thấp	33
Hình 3.11 Chuẩn hóa dữ liệu văn bản	34
Hình 3.12 Quá trình thử nghiệm lựa chọn các tham số cho Conformer	36
Hình 3.13 Kết quả huấn luyện mô hình Conformer	37
Hình 3.14 Kết quả thử nghiệm các bộ tham số cho AASIST	38
Hình 3.15 Kết quả huấn luyện mô hình AASIST	39
Hình 3.16 Kết quả thử nghiệm các tham số tối ưu cho FastText	41
Hình 3.17 Ma trận nhầm lẫn cho FastText	42
Hình 3.18 Thử nghiệm tất cả các mô hình AAS trên một bộ dữ liệu tự tạo ra	45
Hình 3.19 Quy trình hoạt động tổng quan của ứng dụng	47
Hình 3.20 Màn hình chính ứng dụng Scam Call Guard	49
Hình 3.21 Thử nghiệm ứng dụng detect giọng AI	49
Hình 3.22 Thử nghiệm lừa đảo với transcript	50

DANH MỤC BẢNG BIỂU

Bảng 3.1 Thống kê thu thập giọng nói người thật	24
Bảng 3.2 Thống kê thu thập giọng nói giả mạo	25
Bảng 3.3 Minh họa RMS trước và sau chuẩn hóa	31
Bảng 3.4 Thống kê dữ liệu văn bản trước và sau tiền xử lý	34
Bảng 3.5 Kết quả huấn luyện mô hình FastText	42
Bảng 3.6 thông tin các mô hình âm thanh hiện đại được khảo sát	44
Bảng 3.7 Kết quả trải nghiệm để lựa chọn mô hình Speech to Text (STT)	46

DANH MỤC CÁC TỪ VIẾT TẮT VÀ GIẢI THÍCH CÁC THUẬT NGỮ

Từ viết tắt	Giải thích
AASIST	Audio Anti-Spoofing using Integrated Spectro-Temporal Graph Attention Networks – Một mô hình phát hiện giọng nói giả mạo
AAS	Audio Anti-Spoofing – Phát hiện âm thanh giả mạo
AUC	Area Under the Curve – Chỉ số thể hiện diện tích dưới đường cong ROC, phản ánh hiệu quả phân loại của mô hình
Conformer	Mô hình kết hợp CNN và Transformer cho xử lý giọng nói
EER	Equal Error Rate – Tỷ lệ lỗi khi False Acceptance Rate bằng False Rejection Rate
LSTM	Long Short-Term Memory – Mạng nơ-ron hồi tiếp có khả năng mô hình hóa cả thông tin ngắn hạn và dài hạn trong dữ liệu chuỗi.
NLP	Natural Language Processing – Lĩnh vực thuộc trí tuệ nhân tạo, nghiên cứu cách máy tính hiểu và xử lý ngôn ngữ con người.
RNN	Recurrent Neural Network – Kiến trúc mạng nơ-ron cho phép xử lý dữ liệu tuần tự thông qua cơ chế hồi tiếp.
RNNT	Recurrent Neural Network Transducer – Kiến trúc nhận dạng giọng nói thời gian thực
STT	Speech-to-Text – Công nghệ nhận dạng tiếng nói tự động
TF-IDF	Term Frequency – Inverse Document Frequency – Phương pháp biểu diễn văn bản
VoIP	Voice over Internet Protocol – công nghệ truyền tải tín hiệu thoại qua mạng Internet thay vì mạng điện thoại truyền thống

CHƯƠNG 1 GIỚI THIỆU TỔNG QUAN

1.1 Lý do chọn đề tài

Sự phát triển của trí tuệ nhân tạo và các nền tảng liên lạc trực tuyến đã mang lại nhiều tiện ích cho đời sống hiện đại. Tuy nhiên, song song với sự phát triển đó, các hình thức lừa đảo công nghệ cao, đặc biệt qua cuộc gọi điện thoại, cũng ngày càng gia tăng [1]. Trong những năm gần đây, quá trình chuyển đổi số diễn ra mạnh mẽ, kéo theo sự phát triển nhanh của các thiết bị di động và các nền tảng liên lạc trực tuyến như gọi điện, nhắn tin và họp trực tuyến. Những công nghệ này giúp quá trình trao đổi thông tin trở nên nhanh chóng, tiện lợi và phổ biến hơn trong đời sống hàng ngày. Tuy nhiên, song song với những lợi ích, các hành vi lừa đảo qua điện thoại cũng đang gia tăng nhanh chóng về số lượng và mức độ tinh vi. Trước đây, các cuộc gọi lừa đảo thường khá dễ nhận biết do nội dung đơn giản hoặc giọng nói không tự nhiên. Nhưng hiện nay, với sự phát triển của trí tuệ nhân tạo, đặc biệt là các công nghệ tổng hợp giọng nói và giả mạo giọng nói, kẻ xấu có thể tạo ra giọng nói rất giống người thật [2]. Điều này khiến người nghe khó phân biệt, từ đó làm tăng nguy cơ bị lừa đảo.

Bài toán phát hiện cuộc gọi lừa đảo là một bài toán phức tạp vì liên quan đến nhiều loại dữ liệu khác nhau. Cụ thể, một cuộc gọi thường bao gồm hai thành phần chính là tín hiệu âm thanh và nội dung hội thoại. Do đó, để phát hiện hiệu quả, cần phải phân tích được cả hai loại dữ liệu này [3].

Đối với dữ liệu âm thanh, các phương pháp truyền thống thường sử dụng các đặc trưng như MFCC kết hợp với các mô hình học máy như SVM hoặc Random Forest [4]. Các phương pháp này có ưu điểm là đơn giản và dễ triển khai, tuy nhiên lại gặp hạn chế khi phải xử lý các mối quan hệ phức tạp trong tín hiệu âm thanh, đặc biệt là trong các trường hợp giọng nói giả được tạo ra tinh vi. Sự phát triển của học sâu đã giúp cải thiện đáng kể hiệu quả trong bài toán này. Các mô hình như CNN có khả năng học đặc trưng cục bộ từ phổ âm thanh, trong khi RNN và LSTM có thể xử lý dữ liệu theo chuỗi thời gian. Trong những năm gần đây, các mô hình hiện đại như Transformer đã nâng cao khả năng nắm bắt quan hệ dài hạn trong dữ liệu [5]. Đặc biệt, mô hình Conformer

kết hợp giữa CNN và Transformer giúp khai thác đồng thời đặc trưng cục bộ và ngữ cảnh dài hạn của tín hiệu giọng nói, từ đó nâng cao hiệu quả trong các bài toán nhận dạng và phân tích tiếng nói [6]. Ngoài ra, trong lĩnh vực phát hiện giọng nói giả, mô hình AASIST được đề xuất nhằm phát hiện các dấu hiệu bất thường trong phổ âm thanh thông qua cơ chế chú ý trên đồ thị, cho kết quả tốt trong nhiều bộ dữ liệu chống giả mạo giọng nói [7].

Đối với dữ liệu văn bản, các phương pháp truyền thống như TF-IDF kết hợp với Logistic Regression được sử dụng khá phổ biến do đơn giản và hiệu quả ở mức cơ bản. Tuy nhiên, các phương pháp này chủ yếu dựa vào tần suất xuất hiện của từ, nên chưa thể hiểu được ý nghĩa sâu của câu hoặc ngữ cảnh hội thoại. Các mô hình học sâu như RNN, LSTM hay Transformer đã cải thiện khả năng hiểu ngữ cảnh, nhưng thường yêu cầu tài nguyên tính toán lớn và thời gian xử lý lâu. Trong khi đó, các mô hình nhẹ như fastText có ưu điểm là tốc độ nhanh, dễ triển khai và vẫn đạt hiệu quả tốt trong nhiều bài toán phân loại văn bản, đặc biệt phù hợp với các hệ thống cần xử lý gần thời gian thực [8].

Mặc dù đã có nhiều nghiên cứu được thực hiện, nhưng phần lớn các phương pháp hiện nay chỉ tập trung vào một loại dữ liệu riêng lẻ, tức là chỉ xử lý âm thanh hoặc chỉ xử lý văn bản. Trong thực tế, một cuộc gọi lừa đảo thường có sự kết hợp của nhiều yếu tố, ví dụ như giọng nói có thể mang dấu hiệu bất thường, còn nội dung hội thoại có thể chứa các yêu cầu cung cấp thông tin cá nhân hoặc các kịch bản lừa đảo quen thuộc. Vì vậy, việc kết hợp cả hai loại dữ liệu âm thanh và văn bản được xem là một hướng tiếp cận hợp lý, giúp nâng cao độ chính xác trong việc phát hiện [3]. Khi tận dụng được thông tin từ cả giọng nói và nội dung, hệ thống có thể đưa ra quyết định chính xác hơn so với khi chỉ sử dụng một nguồn dữ liệu.

Từ những lý do trên, đề tài “Nghiên cứu và ứng dụng hệ thống phát hiện cuộc gọi lừa đảo sử dụng học máy” được lựa chọn nhằm xây dựng một hệ thống có khả năng phát hiện cuộc gọi lừa đảo dựa trên cả tín hiệu âm thanh và nội dung hội thoại. Trong đó, các mô hình Conformer và AASIST được sử dụng để phân tích và phát hiện các dấu hiệu bất thường trong giọng nói, còn fastText được sử dụng để xử lý và phân loại nội dung văn bản của cuộc gọi.

Việc kết hợp đồng thời hai nguồn dữ liệu âm thanh và văn bản giúp hệ thống khai thác được nhiều thông tin hơn so với các phương pháp đơn lẻ, từ đó nâng cao độ chính xác và khả năng tổng quát hóa trong quá trình phát hiện. Kết quả của đề tài có thể góp phần hỗ trợ xây dựng các hệ thống cảnh báo sớm cuộc gọi lừa đảo, đáp ứng nhu cầu đảm bảo an toàn thông tin trong bối cảnh các hình thức giả mạo bằng trí tuệ nhân tạo ngày càng phát triển phức tạp.

1.2 Mục tiêu đề án

1.2.1 Mục tiêu tổng quát

Xây dựng hệ thống phát hiện cuộc gọi lừa đảo dựa trên phân tích giọng nói và nội dung hội thoại.

1.2.2 Mục tiêu cụ thể

- Mục tiêu 1: Nghiên cứu và tổng quan các phương pháp trong và ngoài nước liên quan đến phát hiện cuộc gọi lừa đảo, phát hiện giọng nói giả mạo và phân tích nội dung hội thoại bằng xử lý ngôn ngữ tự nhiên.
- Mục tiêu 2: Thu thập và xây dựng bộ dữ liệu phục vụ huấn luyện và đánh giá mô hình, bao gồm dữ liệu âm thanh (giọng nói thật và giọng nói giả) cùng dữ liệu văn bản hội thoại có và không có dấu hiệu lừa đảo.
- Mục tiêu 3: Xây dựng mô hình phát hiện giọng nói giả nhằm phân biệt giữa giọng nói thật và giọng nói được tạo ra hoặc chỉnh sửa bằng công nghệ AI.
- Mục tiêu 4: Phát triển mô hình phân loại nội dung hội thoại nhằm phát hiện các dấu hiệu lừa đảo trong văn bản cuộc gọi.
- Mục tiêu 5: Đề xuất phương pháp kết hợp thông tin từ dữ liệu âm thanh và văn bản nhằm nâng cao độ chính xác.
- Mục tiêu 6: Xây dựng ứng dụng hỗ trợ phát hiện cuộc gọi lừa đảo có khả năng tự động phân tích dữ liệu đầu vào và hiển thị mức độ nguy cơ của cuộc gọi.
- Mục tiêu 7: Đánh giá hiệu năng của hệ thống thông qua các chỉ số thực nghiệm nhằm kiểm chứng tính hiệu quả và khả năng ứng dụng.

1.3 Đối tượng, phạm vi nghiên cứu

1.3.1 Đối tượng nghiên cứu

Đối tượng nghiên cứu là các mô hình học máy và học sâu phục vụ bài toán phát hiện cuộc gọi lừa đảo dựa trên dữ liệu âm thanh và nội dung hội thoại. Cụ thể, đề tài tập trung nghiên cứu các mô hình Conformer và AASIST trong bài toán phát hiện giọng nói giả mạo, cùng với mô hình fastText trong bài toán phân loại nội dung hội thoại có dấu hiệu lừa đảo. Và nghiên cứu phương pháp kết hợp thông tin từ dữ liệu âm thanh và văn bản nhằm xây dựng hệ thống phát hiện cuộc gọi lừa đảo.

1.3.2 Phạm vi nghiên cứu


Đề tài tập trung nghiên cứu và xây dựng hệ thống phát hiện cuộc gọi lừa đảo dựa trên việc phân tích dữ liệu âm thanh và nội dung hội thoại. Dữ liệu sử dụng trong quá trình nghiên cứu bao gồm dữ liệu có sẵn, dữ liệu tự thu thập và dữ liệu mô phỏng phục vụ cho quá trình huấn luyện và đánh giá mô hình. Trong đó, dữ liệu tự thu thập bao gồm các mẫu giọng nói thật, giọng nói giả được tạo bằng công nghệ AI và các nội dung hội thoại có dấu hiệu lừa đảo nhằm tăng tính đa dạng và phù hợp với bài toán thực tế.

Trong phạm vi đồ án, nghiên cứu tập trung vào: Phát hiện giọng nói giả mạo bằng các mô hình học sâu như Conformer và AASIST. Phân loại nội dung hội thoại lừa đảo bằng mô hình fastText. Bên cạnh đó, hệ thống khai thác và kết hợp đa nguồn thông tin từ dữ liệu âm thanh và văn bản nhằm nâng cao độ chính xác. Xây dựng ứng dụng minh họa hỗ trợ phát hiện và cảnh báo cuộc gọi lừa đảo. Đề tài chưa tập trung vào các vấn đề như xử lý dữ liệu thời gian thực quy mô lớn, tối ưu triển khai trên hạ tầng phân tán hoặc tích hợp trực tiếp với hệ thống viễn thông thực tế.

CHƯƠNG 2 CƠ SỞ LÝ THUYẾT

2.1 Tổng quan về học máy

Học máy (Machine Learning) là một lĩnh vực quan trọng thuộc trí tuệ nhân tạo (Artificial Intelligence – AI), tập trung vào việc xây dựng các mô hình có khả năng học từ dữ liệu và cải thiện hiệu suất theo thời gian mà không cần xây dựng các quy tắc xử lý cho từng trường hợp [9]. Học máy giúp hệ thống không cần dựa vào các quy tắc cố định mà có thể tự học từ dữ liệu để đưa ra dự đoán hoặc quyết định. Trong thời gian gần đây, học máy đã được triển khai rộng rãi trong nhiều lĩnh vực như nhận dạng giọng nói, xử lý ngôn ngữ tự nhiên, thị giác máy tính, y tế và an toàn thông tin.



Hình 2.1 Sơ đồ phân cấp Trí tuệ nhân tạo, Học máy, Học sâu

Tùy thuộc vào đặc điểm của dữ liệu và cơ chế học, các phương pháp học máy thường được phân loại thành ba nhóm chính gồm học có giám sát, học không giám sát và học tăng cường [10]. Trong đó, học có giám sát là phương pháp sử dụng dữ liệu đã được gán nhãn để huấn luyện mô hình, thường áp dụng trong các bài toán dự đoán hoặc phân loại. Học không giám sát làm việc với dữ liệu chưa có nhãn, nhằm tìm ra các đặc điểm hoặc cấu trúc ẩn bên trong dữ liệu. Còn học tăng cường là phương pháp mà mô hình học thông qua quá trình tương tác với môi trường, từ đó điều chỉnh hành động dựa trên phần thưởng nhận được.

Thông thường, một bài toán học máy sẽ trải qua các bước như: thu thập dữ liệu, tiền xử lý dữ liệu, trích xuất đặc trưng, lựa chọn mô hình, huấn luyện và đánh giá mô hình. Trong đó, chất lượng dữ liệu đầu vào và phương pháp trích xuất đặc trưng có ảnh

hưởng lớn đến hiệu quả của hệ thống [9]. Ngoài ra, việc lựa chọn thuật toán phù hợp và tối ưu tham số cũng góp phần nâng cao độ chính xác cũng như khả năng tổng quát hóa của mô hình trên dữ liệu thực tế.

Trong những năm gần đây, cùng với sự phát triển của học sâu (Deep Learning), nhiều mô hình hiện đại như CNN, RNN, LSTM và Transformer đã đạt được hiệu quả cao trong các bài toán xử lý âm thanh và xử lý ngôn ngữ tự nhiên [11]. Các mô hình này có khả năng tự động học đặc trưng từ dữ liệu, giúp cải thiện đáng kể hiệu suất so với các phương pháp truyền thống.

Trong đề tài này, học máy được sử dụng để phân tích các cuộc gọi dựa trên đặc trưng giọng nói và nội dung hội thoại. Từ đó, hệ thống có thể nhận diện các dấu hiệu bất thường và hỗ trợ xác định khả năng một cuộc gọi là lừa đảo. Việc lựa chọn và áp dụng các kỹ thuật học máy phù hợp góp phần cải thiện hiệu quả và độ tin cậy của hệ thống.

2.2 Tổng quan về học sâu

Học sâu (Deep Learning) là một nhánh của học máy, tập trung vào việc sử dụng các mô hình mạng nơ-ron nhân tạo có nhiều lớp (deep neural networks) để học và biểu diễn dữ liệu [11]. Học sâu khác với các phương pháp học máy truyền thống ở khả năng tự động học biểu diễn đặc trưng trực tiếp từ dữ liệu, hạn chế sự phụ thuộc vào thiết kế đặc trưng thủ công. Các mô hình học sâu thường được xây dựng dựa trên mạng nơ-ron nhân tạo, bao gồm nhiều tầng như lớp đầu vào, các lớp ẩn và lớp đầu ra. Mỗi lớp có nhiệm vụ xử lý và biến đổi dữ liệu, giúp mô hình học được các đặc trưng từ đơn giản đến phức tạp. Nhờ cấu trúc nhiều tầng, học sâu có khả năng xử lý hiệu quả các dữ liệu phức tạp như âm thanh, hình ảnh và văn bản.

Với sự tiến bộ nhanh chóng trong những năm gần đây, học sâu đã trở thành nền tảng quan trọng cho nhiều ứng dụng thực tiễn như nhận dạng giọng nói, xử lý ngôn ngữ tự nhiên, thị giác máy tính và phát hiện bất thường [11]. Một số mô hình học sâu phổ biến gồm: Mạng nơ-ron tích chập (Convolutional Neural Network – CNN), thường được sử dụng trong xử lý hình ảnh và phân tích phổ âm thanh. Mạng nơ-ron hồi tiếp (Recurrent Neural Network – RNN) và Long Short-Term Memory (LSTM), phù hợp với dữ liệu dạng chuỗi như giọng nói hoặc văn bản. Transformer, là kiến trúc hiện đại


có khả năng học các mối quan hệ dài hạn trong dữ liệu và được sử dụng rộng rãi trong các bài toán xử lý ngôn ngữ tự nhiên [5].

Do đặc điểm kiến trúc nhiều tham số, các mô hình học sâu thường đòi hỏi chi phí tính toán lớn và tập dữ liệu huấn luyện quy mô lớn để đạt hiệu quả tốt. Tuy nhiên, đổi lại, các mô hình học sâu có khả năng đạt độ chính xác cao và tự động học được các đặc trưng quan trọng từ dữ liệu, giúp cải thiện đáng kể hiệu suất so với các phương pháp truyền thống. Trong đề tài này, học sâu được áp dụng để xử lý và phân tích dữ liệu giọng nói cũng như nội dung hội thoại của các cuộc gọi. Các mô hình như Conformer và AASIST được sử dụng để phát hiện các dấu hiệu bất thường trong tín hiệu âm thanh, trong khi fastText hỗ trợ phân loại nội dung văn bản.

2.3 Xử lý tín âm thanh

Xử lý tín hiệu âm thanh đặc biệt là tiếng nói (Speech Processing), là một lĩnh vực quan trọng trong trí tuệ nhân tạo và xử lý tín hiệu số, tập trung vào việc phân tích và khai thác thông tin từ tín hiệu âm thanh. Mục tiêu của lĩnh vực này là phân tích, biến đổi và trích xuất thông tin từ tín hiệu âm thanh để phục vụ cho các bài toán như nhận dạng giọng nói, phân tích cảm xúc hoặc phát hiện bất thường [4].

Tín hiệu giọng nói thực chất là một dạng tín hiệu thời gian liên tục, thường được thu thập thông qua microphone và chuyển đổi thành dạng số để xử lý. Tuy nhiên, dữ liệu âm thanh ban đầu thường chứa nhiều nhiễu và thông tin dư thừa, vì vậy cần trải qua các bước tiền xử lý như lọc nhiễu, chuẩn hóa âm lượng và cắt đoạn tín hiệu để đảm bảo chất lượng đầu vào cho mô hình.



Hình 2.2 Quy trình tổng quát xử lý tín hiệu âm thanh

Sau bước tiền xử lý, tín hiệu âm thanh sẽ được trích xuất đặc trưng nhằm biểu diễn dữ liệu dưới dạng phù hợp hơn cho các thuật toán học máy. Một số đặc trưng phổ biến có

thể kể đến như MFCC (Mel-Frequency Cepstral Coefficients), spectrogram hoặc các đặc trưng về cao độ và năng lượng của tín hiệu [4]. Những đặc trưng này giúp mô hình nắm bắt các thông tin quan trọng trong tín hiệu giọng nói.

Trong các hệ thống hiện đại, các mô hình học sâu như CNN, RNN hoặc LSTM và Transformer thường được sử dụng để xử lý dữ liệu âm thanh [11]. Các mô hình này có khả năng học trực tiếp từ dữ liệu dạng chuỗi hoặc dữ liệu phổ âm thanh, từ đó phát hiện các mẫu và đặc điểm phức tạp trong tín hiệu giọng nói. Đặc biệt, các mô hình như Conformer [6] và AASIST [7] đã cho thấy hiệu quả cao trong các bài toán nhận dạng giọng nói và phát hiện giọng nói giả.

Trong phạm vi đề tài này, xử lý tín hiệu âm thanh được sử dụng để phân tích đặc trưng giọng nói trong các cuộc gọi điện thoại. Thông qua việc trích xuất và xử lý các đặc trưng âm thanh, hệ thống có thể nhận diện các dấu hiệu bất thường như giọng nói giả lập, ngữ điệu không tự nhiên hoặc các mẫu âm thanh đáng ngờ, góp phần hỗ trợ việc phát hiện các cuộc gọi lừa đảo.

2.4 Xử lý ngôn ngữ tự nhiên

Xử lý ngôn ngữ tự nhiên (Natural Language Processing – NLP) là một lĩnh vực trong trí tuệ nhân tạo, nghiên cứu các phương pháp giúp máy tính có khả năng hiểu và xử lý ngôn ngữ con người ở cả dạng văn bản và giọng nói [11]. NLP là nền tảng cho nhiều ứng dụng xử lý ngôn ngữ tự nhiên, bao gồm chatbot, dịch máy, phân tích cảm xúc cũng như phát hiện và kiểm duyệt nội dung độc hại.

Dữ liệu ngôn ngữ tự nhiên thường ở dạng phi cấu trúc, do đó cần trải qua các bước tiền xử lý trước khi đưa vào mô hình học máy. Các bước phổ biến gồm tách từ, loại bỏ từ dừng (Stopwords Removal), chuẩn hóa văn bản và chuyển đổi dữ liệu sang dạng số. Một số phương pháp biểu diễn văn bản thường được sử dụng như Bag of Words (BoW), TF-IDF hoặc Word Embedding như Word2Vec và GloVe [10].

Trong các hệ thống NLP hiện đại, các kiến trúc học sâu như RNN, LSTM và đặc biệt là Transformer đóng vai trò quan trọng và được ứng dụng phổ biến [5]. Những mô hình này có khả năng hiểu ngữ cảnh và mối quan hệ giữa các từ trong câu, từ đó nâng


cao hiệu quả trong các bài toán như phân loại văn bản, nhận diện ý định và phát hiện nội dung bất thường.

Trong phạm vi đề tài này, NLP được sử dụng để phân tích nội dung hội thoại trong các cuộc gọi điện thoại. Thông qua việc xử lý và trích xuất đặc trưng từ văn bản, hệ thống có thể nhận diện các dấu hiệu nghi ngờ như nội dung mang tính lừa đảo, yêu cầu cung cấp thông tin cá nhân hoặc các mẫu câu thường gặp trong các cuộc gọi gian lận. Ngoài ra, mô hình fastText [8] được sử dụng để hỗ trợ phân loại nội dung văn bản nhờ ưu điểm tốc độ xử lý nhanh và khả năng hoạt động hiệu quả trên dữ liệu văn bản thực tế.

2.5 Các mô hình sử dụng cho bài toán

2.5.1 Mô hình Conformer


Conformer là một kiến trúc học sâu được thiết kế cho các bài toán xử lý tín hiệu âm thanh, đặc biệt là nhận dạng giọng nói [6]. Mô hình này kết hợp ưu điểm của mạng tích chập (CNN) và Transformer nhằm khai thác cả đặc trưng cục bộ và ngữ cảnh dài hạn trong dữ liệu.



Hình 2.3 Cấu trúc tổng quan Conformer

Đầu tiên, lớp embedding có nhiệm vụ biến đổi dữ liệu đầu vào (log-Mel spectrogram) thành dạng phù hợp để đưa vào Conformer Encoder. Trong xử lý tiếng nói, embedding không giống word embedding trong NLP mà là biểu diễn theo chuỗi thời gian của tín hiệu âm thanh. Lớp embedding thường gồm các thành phần chính như: Convolution Subsampling, Linear và Dropout. Convolution Subsampling giúp giảm độ dài chuỗi theo thời gian, đồng thời giảm chi phí tính toán cho self-attention. Lớp Linear đưa dữ liệu về cùng một không gian đặc trưng. Dropout sẽ giúp mô hình có thể giảm overfitting và hoạt động ổn định hơn trên dữ liệu chưa thấy. Nhờ bước này, dữ liệu âm thanh ban đầu được chuẩn hóa về kích thước và dạng biểu diễn, giúp các bước sau xử lý dễ hơn.

Tiếp theo, thành phần cốt lõi của mô hình là các Conformer Block. Đây là phần trung tâm của kiến trúc Conformer, được thiết kế nhằm khắc phục một số hạn chế của Transformer truyền thống trong xử lý tín hiệu tiếng nói [5] [6]. Cụ thể, mặc dù self-attention có khả năng nắm bắt mối quan hệ dài hạn rất tốt, nhưng lại chưa khai thác hiệu quả các đặc trưng cục bộ trong tín hiệu âm thanh.



Hình 2.4 Cấu trúc Conformer Blocks

Trong bài toán phân biệt giọng thật và giọng giả, mục tiêu là lấy được đặc trưng chung của toàn bộ tín hiệu để phân loại, không cần tạo chuỗi đầu ra. Vì vậy, mô hình chỉ sử dụng phần encoder (encoder-only). Cách này giúp giảm độ phức tạp nhưng vẫn đạt hiệu quả tốt. Mỗi Conformer Block gồm 3 thành phần chính: Self-attention: học mối quan hệ dài hạn Convolution: học đặc trưng cục bộ Feed-forward (FFN): tăng khả năng biểu diễn của mô hình Nhờ đó, mô hình hiểu được cả thông tin tổng thể và chi tiết của tín hiệu giọng nói.

Trong đó, Feed Forward Module giúp biến đổi đặc trưng đầu vào để mô hình học được các quan hệ phức tạp hơn. Khác với Transformer thông thường, Conformer chỉ lấy một nửa đầu ra của FFN rồi cộng với dữ liệu đầu vào ban đầu, giúp giữ lại thông tin gốc và làm cho mô hình học ổn định hơn. Feed Forward Module được biểu diễn như sau:

$$FFN(x) = W_2 \cdot Swish(W_1 x + b_1) + b_2 \quad (2-1)$$

Trong đó x : vector đầu vào của mô hình. $W1, W2$: ma trận trọng số của các lớp tuyến tính. $b1, b2$: vector bias tương ứng. Swish: hàm kích hoạt phi tuyến, được sử dụng nhằm tăng cường khả năng biểu diễn và hiệu quả học của mô hình

Khác với Transformer truyền thống, Conformer sử dụng cơ chế residual scaling trong Feed Forward Module. Đầu ra của FFN được nhân với $\frac{1}{2}$ trước khi cộng với đầu vào ban đầu nhằm giữ ổn định quá trình huấn luyện và bảo toàn thông tin gốc của tín hiệu [2]. Sau khi qua FFN, đầu ra được cộng với đầu vào theo cơ chế residual connection:

$$y = x + \frac{1}{2}FFN(x) \quad (2-2)$$

Trong đó: x : vector đầu vào, y : đầu ra sau khi áp dụng residual connection, FFN: Feed Forward Module đã tính ở trên

Tiếp theo là thành phần Multi-Head Self-Attention, cho phép mỗi phần của tín hiệu có thể liên hệ với các phần khác trong chuỗi dữ liệu, từ đó giúp mô hình nắm bắt được ngữ cảnh dài hạn của tín hiệu âm thanh. Nhờ cơ chế attention, mô hình có khả năng gán trọng số khác nhau cho các vị trí trong chuỗi đầu vào để tập trung vào thông tin quan trọng. Ngoài ra, Conformer còn sử dụng thông tin vị trí tương đối (Relative Positional Encoding) nhằm khai thác tốt hơn quan hệ thời gian giữa các frame của tín hiệu tiếng nói [6]. Cơ chế Self-Attention được biểu diễn như sau:


$$Attention(Q, K, V) = softmax\left(\frac{QK^T}{\sqrt{d_k}}\right)V \quad (2-3)$$

Trong đó Q (Query): ma trận truy vấn. K (Key): ma trận khóa. V (Value): ma trận giá trị d_k : số chiều của vector Key (dùng để chuẩn hóa). softmax: hàm chuẩn hóa, chuyển giá trị về xác suất

Bên cạnh đó, Convolution Module giúp mô hình học các đặc trưng cục bộ theo thời gian, chẳng hạn như âm tiết hoặc các dấu hiệu bất thường xuất hiện trong thời gian ngắn. Module này thường bao gồm các lớp tích chập kết hợp với hàm kích hoạt và chuẩn hóa, giúp tăng khả năng nhận diện chi tiết của tín hiệu. Cuối mỗi Conformer Block, Layer Normalization được áp dụng nhằm chuẩn hóa đầu ra. Việc này giúp quá trình huấn luyện ổn định hơn, giúp mô hình học hiệu quả hơn, đặc biệt khi xử lý các chuỗi dữ liệu dài.

2.5.2 Mô hình AASIST

Mô hình AASIST (Audio Anti-Spoofing using Integrated Spectro-Temporal Graph Attention Networks) là một hướng tiếp cận tiêu biểu cho bài toán phát hiện giọng nói giả mạo [2] [7]. Mô hình tập trung vào việc khai thác các đặc trưng bất thường trong tín hiệu âm thanh nhằm phân biệt giữa giọng nói thật và giọng nói được tạo ra hoặc chỉnh sửa bằng công nghệ. Ý tưởng chính của AASIST là kết hợp khả năng trích xuất đặc trưng cục bộ của mạng CNN với cơ chế Graph Attention để học mối quan hệ giữa các vùng phổ khác nhau trong tín hiệu âm thanh.



Hình 2.5 Cấu trúc tổng quan AASIST

Trong mô hình AASIST, phần CNN đóng vai trò như một encoder ở đầu vào, giúp trích xuất các đặc trưng cục bộ từ biểu diễn phổ thời gian tần số của tín hiệu giọng nói. Nhờ đó, mô hình có thể nắm bắt được các chi tiết quan trọng như mẫu tần số và những dấu hiệu bất thường thường xuất hiện trong giọng nói tổng hợp. Phép tích chập trong CNN được mô tả bởi công thức sau:

$$X_l = \sigma(W_l * X_{l-1} + b_l) \quad (2-3)$$

Trong đó: X_{l-1} : đầu vào lớp trước, W_l : kernel tích chập, b_l : bias, σ : hàm kích hoạt, X_l : đặc trưng đầu ra

Tiếp theo, cơ chế Graph Attention được áp dụng nhằm khai thác mối quan hệ giữa các vùng phổ khác nhau. Điều này cho phép mô hình phát hiện các mẫu lặp bất thường hoặc sự thiếu biến thiên tự nhiên những đặc điểm thường gặp ở giọng nói giả mạo. Việc kết hợp CNN và Graph Attention giúp AASIST học được biểu diễn đầy đủ hơn, khai thác cả thông tin cục bộ và quan hệ toàn cục trong tín hiệu âm thanh. Cơ chế Graph Attention giúp mô hình tự động học trọng số quan trọng giữa các vùng phổ khác nhau của tín hiệu âm thanh. Những vùng chứa đặc trưng bất thường sẽ được gán trọng số cao hơn để hỗ trợ phát hiện giọng nói giả mạo hiệu quả hơn. Trọng số attention giữa các nút trong đồ thị được tính như sau:

$$\alpha_{ij} = \frac{\exp(e_{ij})}{\sum_{k \in N_i} \exp(e_{ik})} \quad (2-4)$$

Trong đó: α_{ij} : trọng số attention giữa nút i và nút j, e_{ij} : mức độ liên quan giữa hai nút, N_i : tập các nút lân cận của nút i

Sau đó, mô hình sử dụng Attentive Pooling để tổng hợp thông tin từ toàn bộ tín hiệu. Khác với các phương pháp như average pooling hay max pooling, Attentive Pooling cho phép mô hình tập trung nhiều hơn vào những vùng chứa đặc trưng quan trọng, đặc biệt là các dấu hiệu liên quan đến giả mạo. Nhờ vậy, biểu diễn cuối cùng của tín hiệu sẽ mang nhiều thông tin hữu ích hơn cho quá trình phân loại. Quá trình tổng hợp đặc trưng bằng attention được mô tả như sau:

$$z = \sum_{t=1}^T \alpha_t h_t \quad (2-5)$$

Trong đó: h_t : vector đặc trưng tại thời điểm t, α_t : trọng số attention, z: vector biểu diễn cuối cùng

Cuối cùng, các đặc trưng đã được tổng hợp sẽ được đưa vào bộ phân loại (classifier), thường gồm một hoặc nhiều lớp fully connected, để đưa ra kết quả dự đoán. Mô hình sẽ phân loại tín hiệu đầu vào thành giọng nói thật hoặc giọng nói giả mạo dựa trên các đặc trưng đã học được. Xác suất phân loại tín hiệu giả mạo được tính bằng:

$$\hat{y} = \sigma(Wz + b) \quad (2-6)$$

Trong đó: $\hat{y}$: xác suất dự đoán tín hiệu là giả mạo, z : vector đặc trưng đầu ra của mô hình, W : ma trận trọng số của lớp phân loại, b : vector bias, σ : hàm sigmoid dùng để đưa giá trị đầu ra về khoảng từ 0 đến 1.


Một điểm mạnh của AASIST là khả năng kết hợp thông tin theo cả hai chiều: theo thời gian (temporal) và theo tần số (spectral). Điều này đặc biệt hữu ích trong bài toán phát hiện giọng giả, vì các dấu hiệu giả mạo thường xuất hiện ở cả cấu trúc thời gian và phổ tần của tín hiệu âm thanh.

2.5.3 Mô hình FastText

FastText được xây dựng dựa trên Word2Vec nhưng có cải tiến quan trọng khi xử lý văn bản ở mức subword (n-gram ký tự) thay vì chỉ xem mỗi từ là một đơn vị độc lập [8]. Cụ thể, FastText biểu diễn một từ như tập hợp các n-gram ký tự. Các n-gram này được dùng để tạo vector biểu diễn cho từ. Nhờ đó, mô hình có thể hiểu được cấu trúc bên trong của từ và xử lý hiệu quả các trường hợp từ hiếm, từ mới hoặc từ chưa từng xuất hiện trong dữ liệu huấn luyện (out-of-vocabulary). Vector biểu diễn của một từ trong FastText được tính bằng tổng vector của các n-gram ký tự cấu thành từ đó:

$$v_w = \sum_{g \in G_w} z_g \quad (2-7)$$

Trong đó: v_w : vector biểu diễn của từ w , G_w : tập các n-gram ký tự của từ w , z_g : vector biểu diễn của n-gram ký tự g .



Hình 2.6 Sự khác biệt giữa Word2Vec và FastText

Về cơ chế học, FastText sử dụng các mô hình như Skip-gram và CBOW để học embedding từ dữ liệu. Đồng thời, mô hình tích hợp các kỹ thuật tối ưu như Hierarchical Softmax và Negative Sampling nhằm giảm chi phí tính toán và tăng tốc độ huấn luyện, đặc biệt khi làm việc với tập dữ liệu lớn. Skip-gram được tính như sau:

$$P(w_o|w_i) = \frac{\exp(v_{w_o}^T v_{w_i})}{\sum_{w=1}^W \exp(v_w^T v_{w_i})} \quad (2-8)$$

Trong đó: w_i : từ trung tâm, w_o : từ ngữ cảnh, v : vector embedding, W : số lượng từ vựng

FastText có hiệu quả cao trong khi vẫn đảm bảo tốc độ xử lý nhanh và mức tiêu thụ tài nguyên thấp. Ngoài việc học biểu diễn từ, FastText còn hỗ trợ học có giám sát cho các nhiệm vụ như phân loại văn bản, phân tích cảm xúc, nhận diện ngôn ngữ hoặc phát hiện nội dung bất thường. Trong quá trình phân loại, mô hình sử dụng hàm softmax để tính xác suất văn bản đầu vào thuộc về từng lớp khác nhau:

$$P(y|x) = \frac{\exp(W_y h)}{\sum_{i=1}^K \exp(W_i h)} \quad (2-9)$$


Trong đó: x : văn bản đầu vào, h : vector đặc trưng của văn bản, W_y : trọng số tương ứng với lớp y , K : số lượng lớp phân loại, $P(y|x)$: xác suất văn bản thuộc lớp y

Tóm lại, FastText là mô hình xử lý ngôn ngữ tự nhiên có tốc độ huấn luyện nhanh, yêu cầu tài nguyên thấp nhưng vẫn đạt hiệu quả phân loại tốt. Nhờ khả năng khai thác đặc trưng subword, mô hình có thể xử lý hiệu quả các biến thể từ vựng và ngữ nghĩa trong tiếng Việt.

2.6 Các hệ số đánh giá mô hình

2.6.1 Chỉ số AUC

AUC (Area Under the Curve) là một chỉ số phổ biến được sử dụng để đánh giá hiệu năng của các mô hình phân loại, đặc biệt trong các bài toán phân loại nhị phân [12]. AUC là diện tích dưới đường cong ROC (Receiver Operating Characteristic), phản ánh khả năng phân biệt hai lớp của mô hình. AUC được sử dụng để đánh giá hiệu năng của các mô hình Conformer và AASIST.



Hình 2.7 Đường cong ROC và diện tích AUC

Đường cong ROC được xây dựng dựa trên mối quan hệ giữa hai đại lượng là TPR (True Positive Rate – tỷ lệ dự đoán đúng lớp dương) và FPR (False Positive Rate – tỷ lệ dự đoán sai lớp âm thành lớp dương) tại các ngưỡng phân loại khác nhau. Khi thay đổi ngưỡng quyết định, ta sẽ thu được một đường cong ROC, và AUC chính là diện tích nằm dưới đường cong này.

$$TPR = \frac{TP}{TP+FN} \quad (2-10)$$

$$FPR = \frac{FP}{FP+TN} \quad (2-11)$$

Trong các biểu thức trên: TP (True Positive): số mẫu lừa đảo được phát hiện đúng, TN (True Negative): số mẫu bình thường được nhận diện đúng, FP (False Positive) số mẫu bình thường bị dự đoán nhầm là lừa đảo, FN (False Negative): số mẫu lừa đảo bị dự đoán nhầm là bình thường.

Giá trị AUC nằm trong khoảng từ 0 đến 1. Khi AUC tiến gần đến 1, mô hình thể hiện khả năng phân tách hai lớp một cách hiệu quả. Ngược lại, nếu AUC gần 0.5, mô hình hoạt động tương đương với việc dự đoán ngẫu nhiên. Trong thực tế, AUC càng cao cho thấy mô hình có độ tin cậy lớn trong việc phân biệt các lớp. AUC được tính theo công thức:


$$AUC = \int_0^1 TPR(FPR)d(FPR) \quad (2-12)$$

Trong đó: TPR: True Positive Rate, FPR: False Positive Rate, AUC: diện tích dưới đường cong ROC

Một ưu điểm quan trọng của AUC là không phụ thuộc vào việc lựa chọn ngưỡng phân loại cụ thể, do đó phản ánh được hiệu năng tổng thể của mô hình trên nhiều điều kiện khác nhau [12]. Điều này đặc biệt hữu ích trong các bài toán như phát hiện lừa đảo hoặc phát hiện giọng nói giả mạo, rất tốt cho lựa chọn ngưỡng có thể thay đổi tùy theo yêu cầu thực tế.

2.6.2 Chỉ số EER

EER (Equal Error Rate) là một chỉ số quan trọng thường được sử dụng trong các bài toán xác thực và phát hiện giả mạo, đặc biệt là trong xử lý giọng nói. Chỉ số này thể hiện điểm mà tỷ lệ chấp nhận sai (False Acceptance Rate – FAR) bằng với tỷ lệ từ chối sai (False Rejection Rate – FRR). EER được áp dụng để đánh giá khả năng phân biệt giữa giọng nói thật và giọng nói giả của các mô hình Conformer và AASIST.



Hình 2.8 Biểu đồ minh họa Equal Error Rate

Trong đó, FAR là tỷ lệ các mẫu giả mạo bị hệ thống chấp nhận nhầm là hợp lệ, còn FRR là tỷ lệ các mẫu hợp lệ bị hệ thống từ chối nhầm. Khi thay đổi ngưỡng phân loại, hai giá trị này sẽ thay đổi ngược chiều nhau. FAR và FRR được xác định theo các công thức:

$$FAR = \frac{FP}{FP+TN} \quad (2-13)$$

$$FRR = \frac{FN}{FN+TP} \quad (2-14)$$

Trong đó: FP (False Positive): số mẫu giả bị dự đoán nhầm là thật, TN (True Negative): số mẫu giả được dự đoán đúng, FN (False Negative): số mẫu thật bị dự đoán nhầm là giả, TP (True Positive): số mẫu thật được dự đoán đúng.

EER được xác định tại điểm mà hai đường FAR và FRR giao nhau. Giá trị EER càng thấp thì mô hình càng hoạt động tốt, vì điều đó cho thấy cả hai loại lỗi đều được giảm thiểu. Ngược lại, nếu EER cao, mô hình có xu hướng mắc nhiều lỗi trong việc phân biệt giữa các mẫu thật và giả. Giá trị EER được xác định tại điểm mà FAR và FRR bằng nhau:

$$EER = FAR = FRR \quad (2-15)$$

Trong đó: EER (Equal Error Rate): tỷ lệ lỗi cân bằng của hệ thống, FAR (False Acceptance Rate): tỷ lệ mẫu giả bị chấp nhận nhầm là thật, FRR (False Rejection Rate): tỷ lệ mẫu thật bị từ chối nhầm là giả.

Một ưu điểm của EER là cung cấp một thước đo cân bằng giữa hai loại lỗi quan trọng, đặc biệt phù hợp trong các bài toán như phát hiện giọng nói giả mạo hoặc nhận diện lừa đảo, nơi mà cả việc bỏ sót và báo nhầm đều gây ra những hậu quả đáng kể [12] [13].

2.6.3 Chỉ số *F1-score*, *Precision*, *Recall*

Trong các bài toán phân loại văn bản như phát hiện nội dung lừa đảo, việc đánh giá mô hình không chỉ dựa trên độ chính xác tổng thể (Accuracy) mà còn cần xem xét khả năng dự đoán đúng và mức độ phát hiện đầy đủ của mô hình đối với từng lớp dữ liệu. Vì vậy, ba chỉ số Precision, Recall và F1-score được sử dụng để đánh giá hiệu năng của mô hình FastText [9].

Precision là chỉ số phản ánh mức độ chính xác của các dự đoán thuộc lớp dương. Trong bài toán phân loại nội dung lừa đảo, Precision thể hiện tỷ lệ các mẫu được mô hình dự đoán là lừa đảo thực sự là lừa đảo, giúp đánh giá khả năng hạn chế các cảnh báo sai. Precision càng cao thì số lượng dự đoán nhầm càng ít.

$$Precision = \frac{TP}{TP+FP} \quad (2-16)$$

Trong đó: TP (True Positive): số mẫu lừa đảo được dự đoán đúng, FP (False Positive): số mẫu bình thường bị dự đoán nhầm là lừa đảo

Recall cho biết tỷ lệ các mẫu dương được mô hình phát hiện chính xác. Trong bài toán phát hiện nội dung lừa đảo, Recall thể hiện tỷ lệ các mẫu lừa đảo thực sự được mô hình phát hiện đúng. Recall càng cao thì mô hình càng giảm được số lượng mẫu lừa đảo bị bỏ sót.

$$Recall = \frac{TP}{TP+FN} \quad (2-17)$$

Trong đó: TP (True Positive): số mẫu lừa đảo được dự đoán đúng, FN (False Negative): số mẫu lừa đảo bị dự đoán nhầm là bình thường.

F1-score là chỉ số trung bình giữa Precision và Recall, dùng để đánh giá sự cân bằng trong hiệu năng của mô hình phân loại. Chỉ số này đặc biệt hữu ích trong các bài toán dữ liệu mất cân bằng, khi cần đồng thời đảm bảo khả năng phát hiện đúng và hạn chế dự đoán sai. Giá trị F1-score lớn hơn thể hiện mô hình hoạt động hiệu quả hơn.

$$F1 = 2 \times \frac{Precision \times Recall}{Precision + Recall} \quad (2-18)$$

Trong đó: Precision: mức độ chính xác của các dự đoán dương tính, Recall: khả năng mô hình phát hiện đầy đủ các mẫu dương tính trong dữ liệu

Nhìn chung, ba chỉ số Precision, Recall và F1-score giúp đánh giá toàn diện hiệu năng của mô hình FastText trong bài toán phân loại nội dung lừa đảo. Việc kết hợp các chỉ số này cho phép đánh giá không chỉ khả năng dự đoán chính xác mà còn mức độ phát hiện đầy đủ các mẫu lừa đảo, từ đó phản ánh rõ hơn tính hiệu quả và khả năng ứng dụng thực tế của mô hình.

CHƯƠNG 3 XÂY DỰNG MÔ HÌNH VÀ ỨNG DỤNG

3.1 Phân tích bài toán

3.1.1 Mô tả chi tiết bài toán

Trong những năm gần đây, các hình thức lừa đảo qua điện thoại ngày càng phổ biến và tinh vi hơn nhờ sự hỗ trợ của trí tuệ nhân tạo và công nghệ tổng hợp giọng nói. Các đối tượng lừa đảo có thể sử dụng giọng nói giả mạo hoặc các kịch bản hội thoại được chuẩn bị sẵn để đánh lừa người dùng nhằm chiếm đoạt tài sản và thông tin cá nhân. Điều này đặt ra nhu cầu xây dựng các hệ thống có khả năng tự động phát hiện và cảnh báo các cuộc gọi có dấu hiệu lừa đảo.

Đề tài xây dựng hệ thống phát hiện cuộc gọi lừa đảo dựa trên hai nguồn dữ liệu chính gồm tín hiệu âm thanh và nội dung hội thoại. Với dữ liệu âm thanh, hệ thống thực hiện phân loại nhị phân nhằm phân biệt giọng nói thật và giọng nói giả mạo trong lĩnh vực Audio Anti-Spoofing. Tín hiệu âm thanh được chuyển sang dạng log-Mel spectrogram để trích xuất đặc trưng, từ đó mô hình học các dấu hiệu bất thường như nhiễu, biến dạng phổ tần hoặc sự thiếu tự nhiên của giọng nói AI.

Đối với dữ liệu văn bản, hệ thống thực hiện phân loại nội dung hội thoại thành hai nhóm: bình thường và có dấu hiệu lừa đảo. Nội dung lừa đảo thường chứa các đặc điểm như yêu cầu cung cấp thông tin cá nhân, chuyển tiền, giả danh cơ quan chức năng hoặc tạo áp lực tâm lý. Mô hình cần học được các đặc trưng dấu hiệu đó để nhận diện các mẫu hội thoại bất thường này.


Trong nghiên cứu, hai nguồn dữ liệu được xử lý độc lập bằng các mô hình phù hợp. Cụ thể, Conformer kết hợp AASIST được sử dụng để phát hiện giọng nói giả mạo, trong khi FastText được áp dụng để phân loại nội dung hội thoại. Sau đó, kết quả từ các mô hình được kết hợp nhằm đưa ra đánh giá tổng thể về mức độ nguy hiểm của cuộc gọi.

Việc kết hợp đa phương thức (multimodal) giúp hệ thống tận dụng ưu điểm của cả dữ liệu âm thanh và văn bản. So với việc chỉ sử dụng một nguồn dữ liệu riêng lẻ, cách

tiếp cận này giúp nâng cao độ chính xác, tăng khả năng tổng quát hóa và giảm tỷ lệ dự đoán sai trong quá trình phát hiện cuộc gọi lừa đảo.

3.1.2 Quy trình thực hiện

Quy trình thực hiện hệ thống phát hiện cuộc gọi lừa đảo gồm các bước chính: thu thập dữ liệu, tiền xử lý dữ liệu, huấn luyện mô hình, kết hợp kết quả và xây dựng ứng dụng hoàn chỉnh.



Hình 3.1 Quy trình thực hiện

Đầu tiên, dữ liệu âm thanh và nội dung hội thoại được thu thập từ các nguồn công khai, dữ liệu tự xây dựng và dữ liệu mô phỏng. Dữ liệu sau khi thu thập được đưa qua giai đoạn tiền xử lý nhằm chuẩn hóa và tối ưu hóa trước khi sử dụng cho các mô hình. Đối với dữ liệu âm thanh, tín hiệu được chuyển sang dạng log-Mel spectrogram nhằm biểu diễn đặc trưng phù hợp cho quá trình học. Đối với văn bản, dữ liệu được làm sạch và chuẩn hóa.

Tiếp theo, các mô hình được huấn luyện riêng cho từng loại dữ liệu. Cụ thể, Conformer và AASIST được sử dụng để phát hiện giọng nói giả mạo, trong khi FastText được sử dụng để phân loại nội dung hội thoại.

Sau quá trình huấn luyện, kết quả từ các mô hình được kết hợp để đưa ra đánh giá tổng thể về mức độ nguy hiểm của cuộc gọi theo hướng đa phương thức (multimodal). Cuối cùng, toàn bộ hệ thống được tích hợp vào ứng dụng nhằm hỗ trợ tự động phát hiện và cảnh báo các cuộc gọi có dấu hiệu lừa đảo.

3.2 Các công cụ thư viện sử dụng

3.2.1 Môi trường thực nghiệm

Các giai đoạn phát triển và huấn luyện mô hình được triển khai trên Google Colab, trong đó Python được sử dụng làm ngôn ngữ lập trình chính. Nền tảng này còn hỗ trợ cài đặt thư viện nhanh chóng, thuận tiện cho việc thử nghiệm và đánh giá nhiều mô hình khác nhau.

Trong quá trình phát triển ứng dụng sử dụng Visual Studio Code làm môi trường lập trình chính kết hợp với nền tảng Flutter để xây dựng ứng dụng di động đa nền tảng. Flutter cho phép phát triển ứng dụng chạy trên cả Android và iOS, giao diện trực quan và khả năng tích hợp mô hình học máy dễ dàng. Việc sử dụng Flutter giúp hệ thống có thể triển khai thực tế trên thiết bị di động nhằm hỗ trợ phát hiện cuộc gọi lừa đảo theo thời gian thực

3.2.2 Các thư viện chính được sử dụng

Để xây dựng hệ thống phát hiện cuộc gọi lừa đảo sử dụng học máy, đề tài sử dụng nhiều thư viện hỗ trợ xử lý dữ liệu, huấn luyện mô hình và phát triển ứng dụng. Các thư viện chính bao gồm:

PyTorch Là framework học sâu được sử dụng để xây dựng, huấn luyện và tối ưu mô hình phát hiện giọng nói giả mạo.

Torchaudio thư viện thuộc PyTorch, hỗ trợ xử lý dữ liệu âm thanh.

NumPy Thư viện tính toán số học phổ biến trong Python, được sử dụng để xử lý dữ liệu ma trận, thao tác số liệu và hỗ trợ các phép tính thống kê trong quá trình huấn luyện.

SoundFile Thư viện dùng để đọc và ghi file âm thanh định dạng WAV.

Scikit-learn Được sử dụng để tính toán các chỉ số đánh giá mô hình như Accuracy, ROC-AUC và EER (Equal Error Rate), giúp đánh giá hiệu quả phát hiện cuộc gọi lừa đảo.

Flutter Framework được sử dụng để xây dựng giao diện và tích hợp mô hình AI vào ứng dụng phát hiện cuộc gọi lừa đảo trên thiết bị di động.

Dart là ngôn ngữ chính của Flutter, vai trò là ngôn ngữ cốt lõi để phát triển cả logic xử lý và giao diện người dùng.

TorchScript Công cụ chuyển đổi mô hình PyTorch sang định dạng tối ưu cho triển khai thực tế trên thiết bị di động, giúp giảm độ trễ suy luận và tăng hiệu năng hoạt động của ứng dụng.

3.3 Dữ liệu và tiền xử lý

3.3.1 Thu thập dữ liệu

3.3.1.1 Thu thập dữ liệu âm thanh

Dữ liệu âm thanh được xây dựng từ nhiều nguồn khác nhau nhằm phục vụ huấn luyện mô hình phát hiện giọng nói giả mạo tiếng Việt. Các mẫu âm thanh được lựa chọn đa dạng về giới tính, tốc độ nói, cách phát âm và nội dung hội thoại để tăng khả năng học đặc trưng của mô hình. Dữ liệu giọng nói thật được thu thập từ các bộ dữ liệu công khai, video YouTube và ghi âm thực tế, trong khi dữ liệu giả mạo được tạo bằng các mô hình tổng hợp giọng nói. Ngoài ra, các mẫu âm thanh có chất lượng thấp hoặc chứa nhiều tạp âm được loại bỏ để đảm bảo chất lượng dữ liệu đầu vào.

Bảng 3.1 Thống kê thu thập giọng nói người thật

Nguồn thu thập	Mô tả	Thời lượng
Kaggle	Bộ dữ liệu giọng nói người bằng tiếng Việt	1 tiếng
Thu thập thực tế	Ghi âm trực tiếp giọng nói 20 người	40 phút
Youtube	Hội thoại, phát biểu bằng tiếng Việt	1 tiếng 46 phút

Do nguồn dữ liệu tiếng nói giả mạo cho tiếng Việt còn hạn chế, dữ liệu giả mạo chủ yếu được thu thập từ các video có giọng nói do trí tuệ nhân tạo tạo sinh và nhân bản giọng nói từ dữ liệu tiếng nói người thật đã thu thập bằng các mô hình nền tảng giả giọng nói.

Bảng 3.2 Thống kê thu thập giọng nói giả mạo


Nguồn thu thập	Mô tả	Thời lượng
Youtube	Giọng nói do trí tuệ nhân trong các video	1 tiếng 40 phút
Minimax	Nền tảng nhân bản và tạo sinh giọng nói	1 tiếng
Elevenlabs	Nền tảng nhân bản và tạo sinh giọng nói giả lập cảm xúc rất tốt	50 phút

Sau quá trình thu thập và sàng lọc, bộ dữ liệu cuối cùng bao gồm cả tiếng nói người thật và tiếng nói giả mạo với thời lượng khoảng 3,5 giờ cho mỗi loại. Quy mô dữ liệu này được đánh giá là tương đối phù hợp cho quá trình huấn luyện, kiểm thử và đánh giá hiệu quả của mô hình phát hiện tiếng nói giả mạo.

3.3.1.2 Thu thập dữ liệu văn bản hội thoại

Xây dựng tập dữ liệu văn bản hội thoại nhằm phục vụ cho quá trình phân tích nội dung và phát hiện các dấu hiệu lừa đảo trong cuộc gọi. Dữ liệu văn bản được thiết kế theo hướng mô phỏng các tình huống hội thoại thực tế thường xuất hiện trong các cuộc gọi giả mạo hiện nay.

Do dữ liệu văn bản về nội dung lừa đảo bằng tiếng Việt tìm được vô cùng hạn chế, nên trong quá trình thu thập sẽ tập trung tự tạo ra một bộ dữ liệu riêng thông qua các nền tảng Chatbot. Các mẫu được tạo theo phong cách giao tiếp tự nhiên nhằm phản ánh sát với cách nói chuyện thực tế qua điện thoại. Dữ liệu bao gồm cả câu đầy đủ ngữ pháp và các câu nói ngắn, viết tắt, thiếu dấu hoặc có lỗi chính tả nhẹ thường gặp trong giao tiếp hàng ngày.



Hình 3.2 Quy trình tạo bộ dữ liệu văn bản hội thoại

Ở giai đoạn đầu, chatbot được sử dụng để tổng hợp các ngữ cảnh hội thoại thường gặp, bao gồm hội thoại lừa đảo và hội thoại thông thường. Các tình huống lừa đảo gồm giả danh công an, ngân hàng, giao hàng, tuyển dụng hoặc thông báo trúng thưởng, trong khi hội thoại thông thường tập trung vào các cuộc trò chuyện hằng ngày.

Sau đó, một chatbot khác được sử dụng để tạo sinh dữ liệu hội thoại dựa trên các ngữ cảnh đã xây dựng. Các đoạn hội thoại được thiết kế theo phong cách giao tiếp tự nhiên, bao gồm cả câu thiếu dấu, viết tắt hoặc có lỗi chính tả nhẹ nhằm mô phỏng dữ liệu thực tế. Ngoài ra, dữ liệu còn bổ sung các trường hợp khó nhận biết như nội dung trung tính, thay đổi cách xưng hô hoặc chuyển đổi ngữ cảnh liên tục nhằm giúp mô hình tăng khả năng tổng quát hóa và phát hiện hiệu quả hơn các cuộc gọi lừa đảo trong thực tế.


3.3.2 Phân tích dữ liệu

3.3.2.1 Dữ liệu âm thanh

Để nhìn trực quan hơn với hai nhãn và sự khác biệt giữa tiếng nói người thật và tiếng nói giả mạo, phần trực quan sẽ sử dụng dữ liệu người thật tự thu thập với giọng nói giả mạo của cùng một người và nội dung nói thông qua Minimax.

Waveform (dạng sóng) biểu diễn biên độ tín hiệu tiếng nói theo thời gian, cho phép quan sát cấu trúc tổng thể, mức năng lượng và khoảng lặng trong phát ngôn. Qua waveform, có thể thấy tiếng nói người thật thường có dao động tự nhiên và không đều,


trong khi tiếng nói giả mạo có xu hướng ổn định và đều hơn. Đây là bước trực quan ban đầu giúp nhận diện sự khác biệt giữa hai loại tiếng nói.



Hình 3.3 Biểu đồ Waveform trực quan

Qua biểu đồ waveform, có thể thấy giọng nói giả mạo tạo ra có năng lượng khá ổn định, trong khi giọng nói con người thể hiện nhiều dao động tự nhiên và biến thiên nhỏ theo thời gian. Sự khác biệt này là cơ sở để các mô hình học sâu khai thác và phân biệt tiếng nói người thật với tiếng nói giả mạo.

Mel Spectrogram cho thấy cách năng lượng của tiếng nói thay đổi theo thời gian và các dải tần số. Qua trực quan, tiếng nói người thật thường có phổ đa dạng và biến thiên tự nhiên, trong khi tiếng nói giả mạo có xu hướng mượt và đồng đều hơn. Đây là đặc trưng quan trọng để mô hình học sâu phân biệt tiếng nói thật và giả.



Hình 3.4 Biểu đồ Mel Spectrogram trực quan

Waveform phản ánh mức độ biên độ của tín hiệu âm thanh, trong khi Mel Spectrogram thể hiện cấu trúc tần số của tiếng nói. Qua trực quan hóa có thể thấy giọng nói giả mạo thường thiếu các biến thiên tần số tự nhiên và có các dải hài âm đều hơn so với giọng nói thật.

Kết quả cho thấy giọng nói người thật có dao động và biến đổi tự nhiên, còn giọng nói giả mạo thường ổn định, mượt và đồng đều hơn. Những khác biệt này là cơ sở quan

trọng để các mô hình học sâu khai thác đặc trưng và phân biệt giữa tiếng nói thật và tiếng nói giả mạo.

3.3.2.2 Dữ liệu văn bản hội thoại


Dữ liệu được lưu dưới dạng tệp văn bản .txt, trong đó mỗi dòng tương ứng với một mẫu dữ liệu hoàn chỉnh bao gồm nhãn và nội dung hội thoại. Định dạng này được lựa chọn vì có cấu trúc đơn giản, nhẹ, dễ xử lý và tương thích tốt với các thư viện học máy xử lý văn bản như fastText. Ngoài ra, việc lưu dữ liệu theo từng dòng riêng biệt cũng giúp thuận tiện cho quá trình tiền xử lý, huấn luyện, kiểm tra và mở rộng tập dữ liệu trong các giai đoạn tiếp theo.

__label__	normal	a đọc giúp e cái mã xác nhận email để e login máy mới
__label__	scam	dạ em chỉ gọi xác nhận nhẹ thôi không có gì nghiêm trọng đâu chỉ
__label__	normal	anh mở thử app rồi vô phần cài đặt coi còn đăng nhập máy cũ ko
__label__	scam	dạ anh không cần thao tác phức tạp, chỉ cần xác nhận đúng/sai thôi
__label__	scam	e từ bộ phận kỹ thuật microsoft đây máy a đang phát tán mã độc

Hình 3.5 Minh họa dữ liệu văn bản hội thoại


Trong tập dữ liệu, mỗi câu hội thoại được gán nhãn tương ứng để phục vụ cho bài toán phân loại. Các câu thuộc nhóm lừa đảo được gán nhãn __label__ scam, trong khi các câu hội thoại thông thường được gán nhãn __label__ normal. Việc chuẩn hóa dữ liệu theo định dạng nhãn giúp mô hình dễ dàng học và phân biệt giữa hai lớp dữ liệu trong quá trình huấn luyện.

Tập dữ liệu hội thoại được chia thành hai lớp gồm scam và normal với số lượng mẫu tương đối cân bằng. Việc cân bằng dữ liệu giữa hai lớp giúp hạn chế hiện tượng thiên lệch trong quá trình huấn luyện, đồng thời hỗ trợ mô hình học tốt hơn các đặc trưng phân biệt giữa hội thoại lừa đảo và hội thoại thông thường



Hình 3.6 Số lượng mỗi lớp scam và normal của dữ liệu văn bản hội thoại

Đánh giá đặc điểm của tập dữ liệu văn bản hội thoại cần tiến hành thống kê và phân tích độ dài câu trong toàn bộ dữ liệu. Việc phân tích này giúp xác định mức độ đa dạng về số lượng từ giữa các câu hội thoại, đồng thời hỗ trợ lựa chọn độ dài đầu vào phù hợp cho quá trình huấn luyện mô hình học máy.



Hình 3.7 Biểu đồ phân bố độ dài từng văn bản trong dữ liệu

Biểu đồ phân bố độ dài câu cho thấy phần lớn dữ liệu hội thoại tập trung ở các câu ngắn và trung bình, phù hợp với đặc điểm giao tiếp trong các cuộc gọi điện thoại. Độ dài trung bình khoảng 15 từ và trung vị là 13 từ, cho thấy đa số câu hội thoại có cấu trúc ngắn gọn, tự nhiên. Tập dữ liệu vẫn tồn tại một số câu rất ngắn (1 từ) và các câu dài tới 65 từ. Các câu quá ngắn thường thiếu ngữ cảnh ngữ nghĩa, trong khi các câu quá dài có thể làm tăng nhiễu đối với các mô hình như FastText.


Vì vậy, các trường hợp này được loại bỏ và xử lý trước khi đưa vào mô hình nhằm đảm bảo dữ liệu đầu vào đạt chất lượng tốt hơn. Kết quả phân tích cho thấy tập dữ liệu có độ dài câu đa dạng và phù hợp với giao tiếp thực tế qua điện thoại, giúp mô hình học được nhiều kiểu diễn đạt khác nhau và nâng cao khả năng phát hiện các cuộc gọi lừa đảo.a.

3.3.3 Tiền xử lý dữ liệu

3.3.3.1 Tiền xử lý âm thanh

Quá trình tiền xử lý dữ liệu âm thanh được thực hiện nhằm chuẩn hóa và cải thiện chất lượng tín hiệu âm thanh trước khi đưa vào mô hình học sâu. Việc tiền xử lý giúp giảm sự khác biệt giữa các nguồn dữ liệu, hạn chế nhiễu không cần thiết và làm nổi bật các đặc trưng quan trọng phục vụ cho bài toán phát hiện giọng nói giả mạo. Đồng thời, các bước xử lý cũng giúp mô hình học ổn định hơn và nâng cao khả năng phân biệt giữa tiếng nói thật và tiếng nói do trí tuệ nhân tạo tạo ra. Trong nghiên cứu này, dữ liệu âm thanh được xử lý thông qua các bước chính gồm: chuẩn hóa định dạng và tần số lấy mẫu, chuẩn hóa năng lượng tín hiệu, cắt đoạn tiếng nói phù hợp và loại bỏ các đoạn âm thanh có mức năng lượng thấp hoặc chứa quá nhiều khoảng lặng.

Chuẩn hóa định dạng và tần số lấy mẫu: Dữ liệu tiếng nói được thu thập từ nhiều nguồn khác nhau nên tồn tại sự khác biệt về định dạng, số kênh và tần số lấy mẫu. Trong bước này, toàn bộ âm thanh được chuyển về dạng đơn kênh (mono) và chuẩn hóa về cùng tần số lấy mẫu 16 kHz nhằm đảm bảo tính đồng nhất của dữ liệu đầu vào và phù hợp với yêu cầu của mô hình học sâu.



Hình 3.8 Mel Spectrogram trước và sau khi chuẩn hóa 16khz

Sau khi chuẩn hóa, phổ tần của tín hiệu chỉ còn biểu diễn đến khoảng 8 kHz, đây là dải tần quan trọng nhất của tiếng nói con người. Việc chuẩn hóa giúp giảm nhiễu, loại bỏ các thành phần tần số không cần thiết và làm cho mức năng lượng của tín hiệu ổn định hơn. Nhờ đó, dữ liệu trở nên nhất quán hơn giữa các nguồn thu thập khác nhau, đồng thời giúp mô hình học hiệu quả hơn trong việc phân biệt giữa giọng nói thật và giọng nói giả mạo.

Chuẩn hóa năng lượng (RMS normalization): được sử dụng để đưa các tín hiệu tiếng nói về cùng mức cường độ, giúp giảm sự khác biệt do thiết bị thu âm hoặc âm lượng phát âm. Sau khi chuẩn hóa, biên độ tín hiệu trở nên đồng đều hơn nhưng vẫn giữ nguyên đặc trưng thời gian của tiếng nói.


Bảng 3.3 Minh họa RMS trước và sau chuẩn hóa

Trạng thái dữ liệu	RMS
Trước chuẩn hóa	0.01038
Sau chuẩn hóa	0.03113

Trên Mel Spectrogram, năng lượng được phân bố cân bằng và ổn định hơn, hỗ trợ mô hình học hiệu quả và hội tụ nhanh hơn trong quá trình huấn luyện. Đồng thời, mức

khuếch đại được giới hạn để tránh làm tăng nhiễu nền, giúp duy trì đặc trưng tự nhiên của tín hiệu âm thanh.

Cắt đoạn tín hiệu (Segmentation): Do độ dài các tệp âm thanh không đồng nhất, dữ liệu được chia thành các đoạn ngắn có độ dài cố định nhằm phù hợp với đầu vào của mô hình học sâu. Các đoạn có năng lượng quá thấp sẽ được loại bỏ để hạn chế khoảng lặng và nhiễu không cần thiết. Phương pháp này giúp tăng số lượng mẫu huấn luyện, đồng thời đảm bảo tính đồng nhất của dữ liệu đầu vào.




Hình 3.9 Cắt đoạn tín hiệu âm thanh

Waveform gốc thể hiện toàn bộ phát ngôn với độ dài khác nhau và có thể chứa nhiều đoạn ít thông tin. Trong khi đó, các segment sau khi cắt chỉ giữ lại phần tín hiệu chứa tiếng nói chính với thời lượng cố định, giúp việc trích xuất đặc trưng trở nên ổn định và hiệu quả hơn cho quá trình huấn luyện mô hình.

Lọc đoạn có năng lượng thấp Sau khi cắt đoạn tín hiệu, các đoạn có mức năng lượng quá thấp được loại bỏ nhằm hạn chế các khoảng lặng hoặc tín hiệu không chứa thông tin tiếng nói. Việc lọc này giúp giảm nhiễu và đảm bảo các mẫu huấn luyện đều mang

đặc trưng âm thanh hữu ích cho mô hình.

Sau quá trình xử lý, dữ liệu chủ yếu giữ lại các đoạn chứa tiếng nói rõ ràng với mức



Hình 3.10 Lọc đoạn âm thanh có năng lượng thấp


năng lượng ổn định hơn. Điều này giúp tăng tính đồng nhất giữa các mẫu dữ liệu và cải thiện hiệu quả học của mô hình trong bài toán phân biệt giọng nói thật và giọng nói giả mạo.

Quá trình tiền xử lý dữ liệu tiếng nói được thực hiện nhằm chuẩn hóa và làm sạch tín hiệu, đảm bảo đầu vào phù hợp cho các mô hình học sâu. Các bước thực hiện bao gồm chuẩn hóa tần số lấy mẫu, chuẩn hóa năng lượng tín hiệu, cắt đoạn âm thanh có độ dài cố định và loại bỏ các đoạn có năng lượng thấp. Nhờ đó, dữ liệu đầu vào trở nên đồng nhất, giảm nhiễu và giữ lại các đặc trưng tiếng nói quan trọng, tạo điều kiện để mô hình học hiệu quả hơn trong bài toán phát hiện giọng nói giả mạo.

3.3.3.2 Tiền xử lý dữ liệu văn bản hội thoại

Các bước thực hiện giúp giảm nhiễu dữ liệu, loại bỏ các mẫu không phù hợp và đồng nhất cách biểu diễn văn bản. Nhờ đó, dữ liệu đầu vào trở nên ổn định hơn, hỗ trợ mô hình học hiệu quả và nâng cao khả năng phân biệt giữa hội thoại lừa đảo và hội thoại thông thường. Các bước bao gồm: chuẩn hóa văn bản, lọc dữ liệu không hợp lệ, lọc theo độ dài câu, loại bỏ dữ liệu trùng lặp và xáo trộn dữ liệu.

Chuẩn hóa văn bản: quá trình chuẩn hóa đưa toàn bộ nội dung về chữ thường, giúp thống nhất cách biểu diễn văn bản. Các liên kết, số điện thoại dài và ký tự đặc biệt được loại bỏ để hạn chế nhiễu không cần thiết trong dữ liệu. Ngoài ra, các ký tự bị lặp nhiều lần trong lời nói tự nhiên như “alooooo” hoặc “tròiiii” cũng được rút gọn để dữ liệu ổn định hơn nhưng vẫn giữ được ngữ cảnh hội thoại thực tế.



Hình 3.11 Chuẩn hóa dữ liệu văn bản

Lọc dữ liệu và kiểm tra định dạng: Dữ liệu được kiểm tra nhằm đảm bảo tính hợp lệ trước khi đưa vào huấn luyện mô hình. Các dòng sai định dạng, thiếu nội dung hoặc không có nhãn hợp lệ sẽ bị loại bỏ để tránh ảnh hưởng đến chất lượng dữ liệu. Ngoài ra, các câu quá ngắn hoặc quá dài cũng được loại bỏ nhằm giảm nhiễu và giúp dữ liệu đồng đều hơn, từ đó hỗ trợ mô hình học ổn định và hiệu quả hơn.

Loại bỏ dữ liệu trùng lặp và xáo trộn dữ liệu: Các mẫu hội thoại trùng lặp được loại bỏ nhằm hạn chế hiện tượng mô hình ghi nhớ dữ liệu và tăng khả năng học đặc trưng tổng quát. Sau đó, dữ liệu được xáo trộn ngẫu nhiên để phân bố các lớp đồng đều hơn trong quá trình huấn luyện. Điều này giúp mô hình học ổn định hơn, đồng thời nâng cao hiệu quả dự đoán trên dữ liệu thực tế.

Bảng 3.4 Thống kê dữ liệu văn bản trước và sau tiền xử lý

Dạng	Dữ liệu văn bản gốc	Dữ liệu văn bản sau tiền xử lý
Số mẫu	11430	10390
Lừa đảo/ Bình thường	5578/ 5672	5547/ 4843
Câu ngắn nhất	1	5
Câu dài nhất	65	40
Trung bình độ dài câu	15.35	15.34

Kết quả thống kê cho thấy sau quá trình tiền xử lý, số lượng mẫu dữ liệu giảm từ 11.430 xuống còn 10.390 mẫu do các câu không hợp lệ, quá ngắn, quá dài hoặc trùng lặp đã được loại bỏ. Đồng thời, độ dài câu được giới hạn phù hợp hơn cho quá trình huấn luyện, giúp dữ liệu trở nên đồng đều và ổn định hơn. Độ dài trung bình của câu gần như được giữ nguyên, cho thấy quá trình tiền xử lý vẫn đảm bảo được đặc trưng ngôn ngữ quan trọng của dữ liệu hội thoại. Sau xử lý, tập dữ liệu phù hợp hơn cho bài toán phân loại hội thoại lừa đảo và hội thoại thông thường bằng mô hình học máy.

3.4 Triển khai mô hình và ứng dụng

Sau quá trình thu thập và tiền xử lý dữ liệu, các mô hình được triển khai và đánh giá nhằm xác định hiệu quả trong bài toán phát hiện lừa đảo đa phương thức. Đối với dữ liệu âm thanh, hai mô hình Conformer và AASIST được sử dụng để phát hiện giọng nói giả mạo, trong khi FastText được áp dụng cho bài toán phân loại văn bản lừa đảo tiếng Việt.


Các mô hình được thử nghiệm với nhiều bộ siêu tham số nhằm lựa chọn cấu hình phù hợp cho thiết bị Android, đảm bảo cân bằng giữa độ chính xác, tốc độ suy luận và mức sử dụng tài nguyên. Hiệu năng của mô hình được đo lường bằng các chỉ số Accuracy, Precision, Recall, F1-score, AUC và EER. Đồng thời, các kỹ thuật như Early Stopping, Dropout, chuẩn hóa dữ liệu được sử dụng nhằm hạn chế hiện tượng overfitting và cải thiện khả năng khái quát của mô hình.

3.4.1 Huấn luyện, đánh giá mô hình Conformer

3.4.1.1 Chọn tham số tối ưu cho Conformer

Để nâng cao hiệu quả phát hiện giọng nói giả mạo, mô hình Conformer được thực nghiệm với nhiều bộ tham số khác nhau nhằm tìm ra cấu hình phù hợp nhất. Quá trình thực nghiệm tập trung đánh giá ảnh hưởng của các tham số quan trọng đến khả năng học đặc trưng và độ chính xác của mô hình thông qua chỉ số Validation EER. Các tham số được khảo sát bao gồm tốc độ học (Learning Rate), kích thước batch (Batch Size), tỉ lệ dropout, số lượng Conformer Block, số lượng Attention Head và độ dài đầu vào tối đa của tín hiệu (MAX_LEN). Mỗi lần thực nghiệm chỉ thay đổi một tham số

trong khi giữ nguyên các tham số còn lại nhằm đánh giá chính xác mức độ ảnh hưởng của từng yếu tố đến hiệu năng mô hình.



Hình 3.12 Quá trình thử nghiệm lựa chọn các tham số cho Conformer


Kết quả thực nghiệm cho thấy Learning Rate $1e-4$ giúp mô hình hội tụ ổn định và đạt giá trị EER thấp nhất. Đối với Batch Size, giá trị 32 cho kết quả tốt hơn so với các batch quá nhỏ hoặc quá lớn. Tỷ lệ Dropout 0.3 giúp giảm hiện tượng overfitting trong khi vẫn giữ được khả năng học đặc trưng hiệu quả. Ngoài ra, mô hình đạt hiệu quả tốt nhất khi sử dụng 2 Conformer Block và 2 Attention Head, giúp cân bằng giữa khả năng học ngữ cảnh và độ phức tạp tính toán. Giá trị MAX_LEN = 120 được lựa chọn do cho khả năng cân bằng tốt giữa việc giữ ngữ cảnh tín hiệu và tốc độ xử lý của mô hình.

3.4.1.2 Huấn luyện, đánh giá Conformer

Sau khi đã xác định được bộ tham số tối ưu thông qua quá trình thử nghiệm, các tham số này được sử dụng để tiến hành huấn luyện chính thức mô hình Conformer. Mục tiêu của giai đoạn này là đánh giá hiệu quả thực sự của mô hình trong điều kiện huấn luyện đầy đủ và ổn định trên toàn bộ tập dữ liệu. Huấn luyện được thực hiện trong tối đa 50 epoch nhằm đảm bảo hiệu quả hội tụ của mô hình. Tuy nhiên, để tránh hiện tượng overfitting và giảm thời gian huấn luyện không cần thiết, cơ chế Early Stopping được

áp dụng. Cụ thể, quá trình huấn luyện sẽ được dừng tự động nếu hiệu suất trên tập validation không cải thiện trong 5 epoch liên tiếp. Chiến lược này giúp cân bằng giữa hiệu quả học của mô hình và chi phí tính toán, đồng thời đảm bảo mô hình không bị ghi nhớ quá mức dữ liệu huấn luyện.

Trong giai đoạn training, các chỉ số AUC và EER trên tập validation được sử dụng để đánh giá và theo dõi hiệu suất mô hình. Mô hình tốt nhất sẽ được lưu lại dựa trên giá trị EER nhỏ nhất nhằm đảm bảo khả năng phân biệt giữa hai lớp dữ liệu đạt hiệu quả cao nhất.



Hình 3.13 Kết quả huấn luyện mô hình Conformer


Trong quá trình huấn luyện, mô hình cho thấy khả năng hội tụ tốt khi Train AUC tăng từ 0.6223 lên 0.9909 và Validation AUC tăng từ 0.8286 lên 0.9823. Đồng thời, chỉ số EER giảm mạnh từ 0.2329 xuống 0.0205, cho thấy khả năng phát hiện giọng nói giả mạo được cải thiện rõ rệt. Giá trị EER tốt nhất đạt được tại epoch 8, đây cũng là thời điểm mô hình đạt hiệu suất tối ưu trên tập validation. Bên cạnh đó, khoảng cách giữa Train AUC và Validation AUC không lớn, cho thấy mô hình có khả năng tổng quát hóa tốt và chưa xuất hiện hiện tượng overfitting đáng kể. Việc áp dụng Early Stopping giúp mô hình dừng huấn luyện tại thời điểm phù hợp, góp phần nâng cao hiệu quả trên dữ liệu kiểm thử.

3.4.2 Huấn luyện, đánh giá mô hình AASIST

3.4.2.1 Chọn tham số tối ưu cho AASIST

Để nâng cao hiệu quả phát hiện giọng nói giả mạo, mô hình AASIST được thực nghiệm với nhiều bộ siêu tham số khác nhau nhằm xác định cấu hình tối ưu nhất. Quá trình thực nghiệm tập trung đánh giá ảnh hưởng của các tham số quan trọng đến khả năng học đặc trưng và hiệu suất phân loại của mô hình thông qua chỉ số Validation EER.

Các tham số được khảo sát bao gồm tốc độ học (Learning Rate), cấu trúc đồ thị kNN (Graph k), kích thước batch (Batch Size), chiều kích đặc trưng (Feature Dimension), tỉ lệ dropout và độ dài đầu vào tối đa của tín hiệu (MAX_LEN). Trong quá trình thực nghiệm, mỗi lần chỉ thay đổi một tham số trong khi giữ cố định các tham số còn lại, nhằm đảm bảo tính khách quan trong việc đánh giá mức độ ảnh hưởng của từng yếu tố.




Hình 3.14 Kết quả thử nghiệm các bộ tham số cho AASIST

Dựa trên kết quả thu được, mô hình đạt hiệu suất tốt nhất khi sử dụng Learning Rate = $1e-4$, giúp quá trình hội tụ ổn định và đạt EER thấp nhất. Đối với Graph k, giá trị k = 8 cho kết quả tối ưu, thể hiện khả năng cân bằng tốt giữa khai thác quan hệ cục bộ và

tránh nhiễu. Về kích thước batch, giá trị 8 cho kết quả tốt hơn so với các batch quá nhỏ hoặc quá lớn, do đảm bảo sự ổn định trong quá trình cập nhật gradient. Với chiều kích đặc trưng, giá trị 128 cho hiệu suất tốt nhất, giúp mô hình đủ khả năng biểu diễn nhưng không gây quá tải tham số. Đối với tỉ lệ dropout, giá trị 0.3 được lựa chọn là tối ưu, giúp giảm hiện tượng overfitting trong khi vẫn giữ được khả năng học đặc trưng hiệu quả. Cuối cùng, giá trị $MAX_LEN = 400$ giúp mô hình cân bằng giữa việc giữ đủ ngữ cảnh của tín hiệu và chi phí tính toán. Tổng thể, bộ siêu tham số tối ưu thu được giúp mô hình AASIST đạt hiệu suất phân loại tốt nhất, đồng thời đảm bảo tính ổn định và khả năng tổng quát hóa trên dữ liệu giọng nói thật và giả.

3.4.2.2 Huấn luyện AASIST

Sau khi xác định được bộ siêu tham số tối ưu, mô hình AASIST được tiến hành huấn luyện chính thức nhằm đánh giá khả năng phát hiện giọng nói giả mạo trên tập dữ liệu. Quá trình huấn luyện được thiết lập với số epoch tối đa là 40, đồng thời, cơ chế Early Stopping được áp dụng với patience bằng 6 epoch để tránh hiện tượng overfitting và giảm thời gian huấn luyện không cần thiết. Mô hình tốt nhất sẽ được lưu lại dựa trên giá trị Validation EER nhỏ nhất.



Hình 3.15 Kết quả huấn luyện mô hình AASIST

Trong quá trình huấn luyện, mô hình cho thấy khả năng hội tụ ổn định khi Train AUC tăng từ 0.6615 lên 0.9399 và Validation AUC đạt mức cao nhất 0.9826. Đồng thời, chỉ


số Validation EER giảm mạnh từ 0.1854 xuống còn 0.0662 tại epoch 6, cho thấy khả năng phát hiện giọng nói giả mạo được cải thiện rõ rệt. Sau epoch 6, giá trị EER chỉ dao động nhẹ và không vượt qua kết quả tốt nhất trước đó.

Bên cạnh đó, sự chênh lệch giữa Train AUC và Validation AUC không quá lớn, cho thấy mô hình có khả năng tổng quát hóa tốt và chưa xuất hiện overfitting nghiêm trọng. Nhờ áp dụng Early Stopping, quá trình huấn luyện được dừng đúng thời điểm nhằm tránh huấn luyện dư thừa. Kết quả thực nghiệm cho thấy mô hình AASIST đạt hiệu quả cao trong bài toán phát hiện giọng nói giả mạo với Validation AUC trên 98% và EER thấp nhất khoảng 6.6%.

3.4.3 Huấn luyện đánh giá mô hình FastText

3.4.3.1 Chọn tham số tối ưu cho FastText

Quá trình thực nghiệm tập trung khảo sát ảnh hưởng của các tham số quan trọng đến khả năng biểu diễn ngữ nghĩa và hiệu quả phân loại của mô hình thông qua chỉ số Equal Error Rate (EER). Các tham số được khảo sát bao gồm tốc độ học (learning rate), số lượng n-gram từ (word n-grams), kích thước n-gram ký tự tối thiểu và tối đa (minn, maxn), kích thước vector biểu diễn (embedding dimension) và số epoch huấn luyện. Mỗi lần thực nghiệm chỉ thay đổi một tham số trong khi giữ nguyên các tham số còn lại nhằm đảm bảo tính khách quan trong việc đánh giá mức độ ảnh hưởng của từng yếu tố.



Hình 3.16 Kết quả thử nghiệm các tham số tối ưu cho FastText

Kết quả thực nghiệm cho thấy learning rate khoảng 0.5 cho hiệu quả tốt nhất, giúp mô hình hội tụ ổn định mà không gây dao động lớn trong quá trình học. Đối với word n-grams, giá trị 3 mang lại hiệu quả tối ưu do cân bằng được thông tin ngữ cảnh và độ nhiễu. Tham số minn = 3 và maxn = 5 cho kết quả tốt nhất khi mô hình khai thác hiệu quả đặc trưng ký tự trong tiếng Việt. Ngoài ra, kích thước embedding 100–150 cho hiệu suất tốt nhất, trong khi tăng quá lớn không cải thiện đáng kể và làm tăng độ phức tạp mô hình. Số epoch khoảng 30 là đủ để mô hình hội tụ, vượt quá mức này không mang lại cải thiện rõ rệt và có thể gây overfitting.


3.4.3.2 Huấn luyện FastText

Sau khi xác định được bộ tham số tối ưu, mô hình FastText được tiến hành huấn luyện chính thức nhằm đánh giá hiệu quả trong bài toán phân loại nội dung lừa đảo. Quá trình huấn luyện được thực hiện trên tập dữ liệu gồm 10,390 mẫu, trong đó tập huấn luyện gồm 8,312 mẫu và tập kiểm thử gồm 2,078 mẫu. Mô hình được huấn luyện với learning rate bằng 0.5, số lượng word n-grams bằng 3, kích thước embedding khoảng 100–150 chiều và số epoch huấn luyện là 30. Ngoài ra, mô hình sử dụng đặc trưng subword với minn = 3 và maxn = 5 nhằm khai thác hiệu quả đặc trưng từ vựng và hình thái tiếng Việt.

Bảng 3.5 Kết quả huấn luyện mô hình FastText

Nhãn	Precision	Recall	F1-score
Normal	94.85%	96.17%	95.51%
Scam	96.8%	95.7%	96.25%

Kết quả đánh giá trên tập kiểm thử cho thấy mô hình đạt Accuracy 95.91%, thể hiện khả năng phân loại chính xác cao trên dữ liệu chưa thấy trước đó. Các chỉ số Precision và Recall đều đạt 95.91%, cho thấy mô hình vừa phát hiện tốt các mẫu lừa đảo vừa hạn chế được dự đoán sai. Đồng thời, F1-score Macro đạt 95.88%, phản ánh hiệu suất cân bằng giữa các lớp dữ liệu. Đối với lớp dữ liệu lừa đảo (Scam), mô hình đạt Precision 96.80%, Recall 95.70% và F1-score 96.25%, cho thấy khả năng nhận diện hiệu quả các nội dung lừa đảo. Trong khi đó, lớp dữ liệu bình thường (Normal) đạt F1-score 95.51%, thể hiện khả năng phân biệt tốt giữa hội thoại lừa đảo và hội thoại thông thường.



Hình 3.17 Ma trận nhầm lẫn cho FastText

Với kết quả huấn luyện đạt được, mô hình FastText cho thấy hiệu quả khá tốt trên bộ dữ liệu tự thu thập. Mặc dù FastText là mô hình có kiến trúc tương đối đơn giản so với các mô hình học sâu hiện đại, kết quả thực nghiệm cho thấy mô hình vẫn có khả năng khai thác hiệu quả đặc trưng ngữ nghĩa và ngữ cảnh trong văn bản tiếng Việt. Việc sử dụng kết hợp giữa word n-grams và đặc trưng subword giúp mô hình xử lý tốt các biến

thể từ ngữ, lỗi chính tả hoặc các cách diễn đạt khác nhau thường xuất hiện trong nội dung lừa đảo.

3.4.4 Đánh giá tổng quan quá trình huấn luyện mô hình

Kết quả thực nghiệm trong mục 3.3 cho thấy các mô hình được triển khai đều đạt hiệu quả tốt trên bộ dữ liệu thực nghiệm và có tiềm năng ứng dụng trong bài toán phát hiện cuộc gọi lừa đảo đa phương thức. Đối với dữ liệu âm thanh, hai mô hình Conformer và AASIST đều cho khả năng phát hiện giọng nói giả mạo với độ chính xác cao và giá trị EER thấp. Trong đó, Conformer đạt kết quả nổi bật với EER thấp nhất khoảng 2%, cho thấy khả năng khai thác hiệu quả đặc trưng ngữ âm và ngữ cảnh dài hạn của tín hiệu giọng nói. Mô hình AASIST cũng đạt hiệu năng tốt với Validation AUC trên 98% và EER thấp nhất khoảng 6.6%, thể hiện khả năng học các đặc trưng bất thường của tín hiệu giả mạo thông qua cơ chế Graph Attention.

Đối với dữ liệu văn bản, mô hình FastText đạt Accuracy khoảng 95.91% cùng F1-score cao trên cả hai lớp dữ liệu. Mô hình đạt hiệu quả tốt trong việc phân loại nội dung lừa đảo tiếng Việt, đồng thời đáp ứng yêu cầu xử lý thời gian thực trên các thiết bị di động có tài nguyên hạn chế.

Tổng thể, các kết quả thực nghiệm cho thấy mỗi mô hình đều có ưu điểm riêng trong việc xử lý từng loại dữ liệu. Việc kết hợp giữa dữ liệu âm thanh và văn bản giúp nâng cao độ chính xác, độ ổn định và khả năng phát hiện lừa đảo của hệ thống so với các phương pháp chỉ sử dụng một nguồn dữ liệu đơn lẻ.

3.5 Thử nghiệm các mô hình khác

Để đánh giá khách quan hiệu quả của các mô hình được đề xuất, đề tài tiến hành thử nghiệm thêm một số kiến trúc học sâu hiện đại thường được sử dụng trong các bài toán phân loại âm thanh và phát hiện giọng nói giả mạo. Việc so sánh với các mô hình này giúp làm rõ ưu điểm, hạn chế cũng như tính phù hợp của từng mô hình đối với bài toán phát hiện cuộc gọi lừa đảo trên thiết bị di động. Ở phần này tất nhiên sẽ là các mô hình mã nguồn mở hiện có.

Trong nghiên cứu này, ba mô hình RawNet2, Wav2Vec2 và AASIST-L được lựa chọn nhằm phục vụ việc đánh giá và so sánh hiệu năng. Đây đều là những kiến trúc tiêu

biểu trong các nghiên cứu gần đây về nhận dạng tiếng nói và phát hiện giọng nói giả mạo.


Bảng 3.6 thông tin các mô hình âm thanh hiện đại được khảo sát

Mô hình	Kiến trúc	Ưu điểm	Nhược điểm
RawNet2	CNN + Attention Pooling trên waveform	Xử lý trực tiếp waveform, kiến trúc gọn nhẹ	Khả năng nắm bắt các phụ thuộc dài hạn còn hạn chế
Wav2Vec2	Self-Supervised Transformer	Khả năng học đặc trưng âm thanh mạnh, hiệu quả cao	Kích thước lớn, yêu cầu tài nguyên cao
AASIST-L	Graph Attention Network rút gọn	Tối ưu cho phát hiện giọng nói giả mạo, ít tham số	Hiệu quả thấp hơn AASIST đầy đủ

RawNet2 là mô hình xử lý trực tiếp tín hiệu âm thanh dạng sóng (raw waveform) mà không cần trích xuất đặc trưng thủ công. Mô hình sử dụng các lớp tích chập sâu kết hợp cơ chế attention để học đặc trưng âm thanh, đồng thời có số lượng tham số tương đối nhỏ so với các kiến trúc Transformer hiện đại.

Wav2Vec2 là mô hình học biểu diễn tín hiệu âm thanh theo cơ chế tự giám sát, được thiết kế nhằm khai thác đặc trưng từ dữ liệu giọng nói chưa gán nhãn. Mô hình được huấn luyện trước trên lượng lớn dữ liệu âm thanh và có khả năng trích xuất các đặc trưng ngữ âm chất lượng cao, từ đó đạt hiệu quả tốt trong nhiều tác vụ xử lý tiếng nói.

AASIST-L là phiên bản rút gọn của AASIST, được thiết kế nhằm giảm số lượng tham số và chi phí tính toán trong khi vẫn duy trì hiệu quả phát hiện giọng nói giả mạo. Mô hình thích hợp cho các hệ thống đòi hỏi thời gian đáp ứng ngắn và môi trường có giới hạn về năng lực tính toán.



Hình 3.18 Thử nghiệm tất cả các mô hình AAS trên một bộ dữ liệu tự tạo ra

Mỗi mô hình đều sở hữu các đặc trưng riêng, đồng thời tồn tại những điểm mạnh và hạn chế nhất định. Wav2Vec2 đạt hiệu quả cao nhờ khả năng học biểu diễn âm thanh tự giám sát và khả năng chống chịu tốt với nhiễu, tuy nhiên yêu cầu tài nguyên tính toán lớn. Conformer cân bằng giữa độ chính xác và khả năng xử lý ngữ cảnh dài nhưng vẫn có chi phí tính toán tương đối cao. AASIST và AASIST-L được thiết kế chuyên biệt cho bài toán phát hiện giọng nói giả mạo, có kích thước nhỏ và tốc độ xử lý nhanh hơn, phù hợp với các hệ thống thời gian thực. Trong khi đó, RawNet2 có kiến trúc đơn giản và nhẹ nhưng hiệu quả phát hiện giọng nói giả mạo thấp hơn các mô hình hiện đại do kiến trúc đã cũ không thể bắt kịp xu hướng phát triển hiện nay. Nhìn chung, Wav2Vec2 và Conformer cho hiệu quả ổn định hơn trên dữ liệu chưa thấy, trong khi AASIST và AASIST-L phù hợp với các ứng dụng yêu cầu tốc độ xử lý cao và tài nguyên hạn chế.

3.6 Xây dựng ứng dụng

Sau khi hoàn thành quá trình huấn luyện và đánh giá các mô hình phát hiện giọng nói giả mạo và phân loại nội dung lừa đảo, đề tài tiến hành xây dựng ứng dụng Android nhằm mô phỏng hệ thống phát hiện cuộc gọi lừa đảo theo thời gian thực. Ứng dụng được phát triển theo hướng xử lý đa phương thức (multimodal), kết hợp phân tích tín hiệu âm thanh và nội dung hội thoại, đồng thời ưu tiên xử lý cục bộ trên thiết bị để tăng tính riêng tư và giảm phụ thuộc vào máy chủ bên ngoài. Hệ thống gồm hai phần chính: Flutter dùng để xây dựng giao diện và hiển thị kết quả; Android Native xử lý

các tác vụ nền như phát hiện cuộc gọi, thu âm, chạy mô hình học máy và hiển thị cảnh báo overlay.


Bảng 3.7 Kết quả trải nghiệm để lựa chọn mô hình Speech to Text (STT)

Model STT	Ưu điểm	Nhược điểm
Vosk	Rất nhẹ và rất nhanh	Rất kém hầu như sai hết như random
Whisper	Chất lượng khá tốt trong mức ổn, cũng khá nhẹ	Chạy siêu chậm, không hẳn là mô hình cho realtime
NVIDIA Citrinet	Chất lượng tốt	Khó dùng, nặng
Zipformer-RNNT	Tốt, nhẹ, nói phát âm ngay, rất hợp tiếng Việt	Khả năng xử lý các biến thể giọng nói địa phương còn hạn chế

Sau khi thử nghiệm và đánh giá trên 4 mô hình STT (chủ yếu lựa chọn cho điện thoại dùng và có dung lượng nhẹ để dù máy yếu cũng dùng được), kết quả cho thấy Zipformer-RNNT là mô hình cho hiệu năng tổng thể tốt nhất khi xét trên nhiều tiêu chí như độ chính xác, tốc độ xử lý, khả năng chạy thời gian thực và mức độ tối ưu tài nguyên trên thiết bị di động. Mô hình này cho thấy sự cân bằng khá tốt giữa các yếu tố, không bị lép vế rõ rệt ở tiêu chí nào so với các mô hình còn lại. Tuy nhiên, một hạn chế của Zipformer-RNNT là khả năng nhận dạng giọng địa phương hoặc cách phát âm không rõ ràng vẫn chưa thực sự tối ưu, dẫn đến một số trường hợp nhận dạng sai nếu người nói không phát âm rõ.

Trong quá trình triển khai thực tế đã gặp một số hạn chế liên quan đến bảo mật âm thanh của các thiết bị. Hệ điều hành thường chặn ứng dụng bên thứ ba truy cập đồng thời microphone hoặc ghi âm trực tiếp cuộc gọi, đặc biệt với các ứng dụng VoIP như Messenger, Zalo... Nên với các cuộc gọi thông thường hệ thống có thể thu âm thông qua microphone của thiết bị khi ứng dụng chạy nền. Đối với các ứng dụng như trên cách dễ nhất nhưng chỉ có ít cơ hội dùng được nếu app đó cho phép là sử dụng screen audio để thu âm thanh phát ra từ cuộc gọi, tuy nhiên cách này chỉ thu được âm thanh từ phía bên kia cuộc gọi và yêu cầu người dùng tự cấp quyền capture trong ứng dụng. Vì các giới hạn trên, trong phần thực nghiệm hệ thống có trường hợp hoạt động được

hoặc không thể tham gia xử lý cuộc gọi tùy theo ứng dụng sử dụng. Nhưng chúng ta cũng có thể dùng ứng dụng này xem youtube để biết đó là giọng AI hay không nên khá thú vị.



Hình 3.19 Quy trình hoạt động tổng quan của ứng dụng

Khi ứng dụng được mở, một cửa sổ nổi sẽ xuất hiện để hỗ trợ quá trình giám sát và cảnh báo. Âm thanh được thu nhận theo thời gian thực từ microphone hoặc thông qua audio playback capture. Dữ liệu âm thanh được chia thành các đoạn ngắn và xử lý song song theo hai nhánh: Nhánh âm thanh: đưa vào mô hình Conformer và AASIST để phát hiện giọng nói giả mạo. Nhánh văn bản: chuyển giọng nói thành văn bản bằng mô hình hynt/Zipformer-30M-RNNT-6000h trên huggingface, sau đó đưa vào FastText để phân loại nội dung lừa đảo. Kết quả từ hai nhánh được tổng hợp để tính toán điểm rủi ro cuối cùng. Ứng dụng cập nhật kết quả cảnh báo theo thời gian thực trên giao diện.

Đối với Conformer điểm đánh giá sẽ tính như sau:

$$S_{Conformer} = 1 - P_{human} = 1 - \frac{1}{1 + e^{-z_c}} \quad (3-1)$$

z_c : logit đầu ra của mô hình Conformer. P_{human} : xác suất mẫu là giọng người. $S_{Conformer}$: điểm AI do Conformer tạo ra (càng gần 1 càng nghiêng về AI, càng gần 0 càng nghiêng về người).

Trong mô hình AASIST, điểm số được xác định như sau:

$$S_{AASIST} = \frac{1}{1 + e^{\frac{aiLogit - humanLogit + 0.85}{0.85}}} \quad (3-2)$$

Trong đó: aiLogit: logit của lớp AI. humanLogit: logit của lớp Human. S_{AASIST} : xác suất mẫu được đánh giá là giọng AI, nằm trong khoảng $[0,1]$.

Transcript đầu vào được chuẩn hóa (normalize), token hóa (tokenize) và mã hóa thành chuỗi gồm 40 token trước khi đưa vào mô hình fastText được tính như sau:

$$S_{fastText} = \frac{1}{1+e^{-(scamLogit-normalLogit)}} \quad (3-3)$$

Trong đó: scamLogit: logit của lớp scam. normalLogit: logit của lớp normal. $S_{fastText}$: xác suất văn bản được phân loại là scam.

Sau khi thu được kết quả từ hai nhánh xử lý, hệ thống thực hiện kết hợp các điểm dự đoán để tính toán mức độ rủi ro cuối cùng:

$$Score = 0.3 \times (0.8 \times S_{Conformer} + 0.2 \times S_{AASIST}) + 0.7 \times S_{fastText} \quad (3-4)$$

Trong đó: $S_{Conformer}$: điểm dự đoán từ Conformer, S_{AASIST} : điểm dự đoán từ AASIST, $S_{fastText}$: điểm dự đoán fastText.


Để làm rõ quy trình vận hành của ứng dụng cũng như trải nghiệm sử dụng thực tế, một số hình ảnh thu được trong quá trình thử nghiệm được trình bày dưới đây. Các hình ảnh thể hiện giao diện người dùng, kết quả nhận dạng và phân tích dữ liệu đầu vào, cũng như cơ chế cảnh báo của hệ thống khi phát hiện các dấu hiệu bất thường hoặc có nguy cơ lừa đảo. Những minh họa này góp phần làm rõ hơn các chức năng đã được trình bày ở các phần trước và cho thấy khả năng vận hành của ứng dụng trong các tình huống thực tế.



Hình 3.20 Màn hình chính ứng dụng Scam Call Guard



Hình 3.21 Thử nghiệm ứng dụng detect giọng AI



Hình 3.22 Thử nghiệm lừa đảo với transcript

Kết quả đạt được cho thấy ứng dụng có tiềm năng lớn trong các bài toán xử lý giọng nói trên thiết bị di động. Với khả năng nhận dạng giọng nói theo thời gian thực và hiệu năng ổn định, ứng dụng có thể mở rộng sang nhiều lĩnh vực như trợ lý giọng nói, nhập liệu bằng giọng nói, hỗ trợ giao tiếp thời gian thực và các hệ thống tương tác người với máy. Ngoài ra, khả năng hoạt động trực tiếp trên thiết bị giúp giảm độ trễ, tăng tính riêng tư và phù hợp với các hệ thống yêu cầu xử lý nhanh, liên tục mà không phụ thuộc hoàn toàn vào kết nối mạng.

KẾT LUẬN

Trong đồ án tốt nghiệp “Nghiên cứu và ứng dụng mô hình học sâu đa phương thức trong phát hiện cuộc gọi lừa đảo trên thiết bị di động”, em đã hoàn thành mục tiêu đề cương đề ra cho nghiên cứu bài toán phát hiện cuộc gọi lừa đảo dựa trên việc phân tích đồng thời tín hiệu giọng nói và nội dung hội thoại. Sau quá trình nghiên cứu và triển khai hệ thống, đề tài đã thu được một số kết quả như sau:

Thu thập và tiền xử lý dữ liệu: Nghiên cứu xây dựng bộ dữ liệu gồm âm thanh cuộc gọi, giọng nói giả mạo và nội dung hội thoại văn bản. Dữ liệu được chuẩn hóa, khử nhiễu, trích xuất đặc trưng và làm sạch nhằm nâng cao hiệu quả huấn luyện mô hình.

Xây dựng mô hình: Hệ thống đa phương thức được xây dựng với Conformer kết hợp AASIST để phân tích giọng nói và FastText để phân tích nội dung hội thoại, giúp nâng cao khả năng phát hiện cuộc gọi lừa đảo.

Xây dựng ứng dụng: Đề tài triển khai ứng dụng Android bằng Flutter kết hợp Android Native, cho phép phát hiện cuộc gọi lừa đảo theo thời gian thực và hiển thị cảnh báo trực tiếp cho người dùng.

Hướng phát triển:

Tiếp tục mở rộng và đa dạng hóa bộ dữ liệu, đặc biệt là các mẫu giọng nói giả mạo và hội thoại lừa đảo mới nhằm nâng cao khả năng tổng quát hóa của hệ thống.

Nghiên cứu và thử nghiệm các mô hình học sâu hiện đại hơn để cải thiện độ chính xác phát hiện, đồng thời giảm độ trễ và tối ưu tài nguyên trên thiết bị di động.

Hoàn thiện cơ chế kết hợp đa phương thức giữa dữ liệu âm thanh và nội dung hội thoại nhằm nâng cao hiệu quả nhận diện các cuộc gọi giả danh, giả mạo.

Mở rộng hệ thống hỗ trợ nhiều ngôn ngữ và nhiều hình thức lừa đảo khác nhau, hướng tới khả năng triển khai thực tế trên quy mô lớn.

TÀI LIỆU THAM KHẢO

- [1] Federal Trade Commission, "Consumer Sentinel Network Data Book 2024," Washington, DC, 2024.
- [2] X. Wang, J. Yamagishi, M. Todisco, H. Delgado and N. Evans, "ASVspoof 2021: Towards Spoofed and Deepfake Speech Detection in the Wild," in *Proc. Interspeech*, Brno, Czech Republic, 2021.
- [3] H. Baltrusaitis, C. Ahuja and L. Morency, "Multimodal Machine Learning: A Survey and Taxonomy," *IEEE Transactions on Pattern Analysis and Machine Intelligence*, vol. 41, no. 2, pp. 423-443, 2019.
- [4] L. Rabiner and B. Juang, Fundamentals of Speech Recognition, Englewood Cliffs, NJ: Prentice Hall, 1993.
- [5] A. Vaswani, N. Shazeer, N. Parmar, J. Uszkoreit, L. Jones, A. Gomez, L. Kaiser and I. Polosukhin, "Attention Is All You Need," in *Advances in Neural Information Processing Systems (NeurIPS 2017)*, Long Beach, CA, USA, 2017.
- [6] A. Gulati, J. Qin, C. Chiu, N. Parmar, Y. Zhang, J. Yu, W. Han, S. Wang, Z. Zhang and Y. Wu, "Conformer: Convolution-augmented Transformer for Speech Recognition," in *Proceedings of INTERSPEECH 2020*, Shanghai, China, 2020.
- [7] J. Kim, M. Todisco, H. Delgado and N. Evans, "Audio Anti-Spoofing using Integrated Spectro-Temporal Graph Attention Networks," in *Proceedings of ICASSP 2022*, Singapore, 2022.
- [8] A. Joulin, E. Grave, P. Bojanowski and T. Mikolov, "Bag of Tricks for Efficient Text Classification," in *Proceedings of EACL 2017*, Valencia, Spain, 2017.
- [9] A. Géron, Hands-On Machine Learning with Scikit-Learn, Keras, and TensorFlow, Sebastopol, CA: O'Reilly Media, 2022.
- [10] C. M. Bishop, Pattern Recognition and Machine Learning, New York, NY: Springer, 2006.
- [11] I. Goodfellow, Y. Bengio and A. Courville, Deep Learning, Cambridge, MA: MIT Press, 2016.
- [12] T. Fawcett, "An Introduction to ROC Analysis," *Pattern Recognition Letters*, vol. 27, no. 8, pp. 861-874, 2006.
- [13] J. Yamagishi, X. Wang and M. Todisco, "ASVspoof 2021: Accelerating Progress in Spoofed and Deepfake Speech Detection," in *ASVspoof Challenge*, Online, 2021.